

CÁC PHƯƠNG PHÁP CHUYỂN ĐỔI GÓI TIN MẠNG CHO HỆ THỐNG PHÁT HIỆN XÂM NHẬP: MỘT KHẢO SÁT

Somaya Eltanbouly, Jezia Zakraoui, Abdulaziz Al-Ali, Abdelhak Belhi, Sandy Rahme và Abdelaziz Bouras

Loại	tài	liệu:	Bài	báo	tạp	chí
Giấy	phép	sử	dụng:	CC	BY	4.0
Đăng	trên	Manara	-	Kho	nghiên cứu	Qatar:
Ngày		nhận		bài:		27/06/2025
Ngày		chấp		nhận:		26/04/2025
Ngày		xuất		bản:		20/05/2025
Phiên	bản		hiện	tại:		19/06/2025
DOI:	10.1109/ACCESS.2025.3581354					27/06/2025

Đơn vị công tác

1. Trung tâm Nghiên cứu Điện toán KINDI, Trường Kỹ thuật, Đại học Qatar, Doha, Qatar.
2. Khoa Khoa học và Kỹ thuật Máy tính, Trường Kỹ thuật, Đại học Qatar, Doha, Qatar.
3. Học viện Nghiên cứu Quốc phòng Joaan Bin Jassim, Al Khor, Qatar.

Tác giả liên hệ: Somaya Eltanbouly (se1701977@qu.edu.qa)

Công trình được hỗ trợ một phần bởi khoản tài trợ nội bộ của Đại học Qatar QU CG-CENG-23/24-236 và một phần bởi Quỹ hỗ trợ truy cập mở của Thư viện Quốc gia Qatar.

Ghi chú bản dịch: Tên mô hình, tập dữ liệu, thuật toán, giao thức, chữ viết tắt và số hiệu trích dẫn được giữ nguyên để bảo đảm đối chiếu chính xác với bản gốc. Danh mục tài liệu tham khảo được giữ nguyên ngôn ngữ gốc.

TÓM TẮT

Hệ thống phát hiện xâm nhập mạng có vai trò thiết yếu trong việc bảo vệ các mạng công nghệ thông tin và công nghệ vận hành trước các cuộc tấn công mạng. Mặc dù các kỹ thuật học máy và học sâu mang lại nhiều triển vọng trong việc cải thiện những hệ thống này, hiệu năng của chúng phụ thuộc mạnh vào cách dữ liệu lưu lượng mạng được chuyển đổi và biểu diễn. Qua khảo sát các công trình phổ biến gần đây, chúng tôi xác định bốn nhóm biểu diễn dữ liệu chính: biểu diễn số, biểu diễn dựa trên điểm ảnh, biểu diễn dựa trên chuỗi và biểu diễn dựa trên đồ thị. Các phép chuyển đổi được khảo sát khai thác thông tin từ gói tin mạng, luồng mạng hoặc kết hợp cả hai. Dựa trên các kết quả trong tài liệu và các thí nghiệm bổ sung thực hiện trên tập dữ liệu CICIDS-2017, chúng tôi đánh giá từng dạng biểu diễn không chỉ theo khả năng cải thiện hiệu năng phát hiện mà còn theo hiệu quả tính toán. Kết quả cho thấy nghiên cứu trong tương lai cần tiếp tục cải thiện kỹ thuật chuyển đổi dữ liệu, đặc biệt về gán nhãn tập dữ liệu và báo cáo thời gian suy luận, nhằm hỗ trợ phát triển các hệ thống phát hiện xâm nhập mạng vững chắc và có tính ứng dụng cao hơn.

Từ khóa: Phát hiện xâm nhập, NIDS, chuyển đổi dữ liệu, chuyển đổi gói tin.

I. GIỚI THIỆU


Hệ thống phát hiện xâm nhập dựa trên mạng (Network-based Intrusion Detection System - NIDS) nhằm phát hiện xâm nhập bằng cách phân tích các gói tin mạng và phân biệt lưu lượng bất thường với lưu lượng bình thường. Những phương pháp ban đầu sử dụng chữ ký và luật để phát hiện các cuộc tấn công đã biết [1]. Cùng với sự phát triển nhanh chóng của trí tuệ nhân tạo và sự cải thiện hiệu năng của các kỹ thuật mới, các phương pháp gần đây chuyển sang sử dụng học máy (ML) và học sâu (DL) để phát hiện bất thường, qua đó mở rộng khả năng phát hiện vượt ra ngoài các cuộc tấn công đã biết [2].

Hai hướng tiếp cận chính được sử dụng trong NIDS để đánh giá lưu lượng mạng là phương pháp dựa trên gói tin và phương pháp dựa trên luồng [3]. Phương pháp thứ nhất kiểm tra lưu lượng trong các tệp bắt gói thô PCAP [1], trong khi phương pháp thứ hai sử dụng các dạng dữ liệu tổng hợp như bản ghi NetFlow [4].

NIDS dựa trên gói tin kiểm tra toàn bộ thông tin của gói, bao gồm thời gian, phần đầu và tải trọng. Các chi tiết được thu thập cho phép NIDS thực hiện kiểm tra gói sâu (Deep Packet Inspection - DPI), qua đó có thể hỗ trợ phát hiện và nhận diện một số loại tấn công. Tuy nhiên, DPI tiêu tốn nhiều tài nguyên vì tạo ra khối lượng dữ liệu rất lớn, đặc biệt trong các mạng tốc độ cao hiện nay, nơi tốc độ gói tin cực lớn [5]. Ngoài ra, ngày càng nhiều ứng dụng mạng được mã hóa, khiến việc phân loại dựa trên gói tin trở nên khó khăn hơn [6].

NIDS dựa trên luồng có thể giảm bớt một số vấn đề của phương pháp dựa trên gói tin. Thay vì xem xét mọi gói tin đi qua một liên kết mạng, phương pháp dựa trên luồng chỉ xem xét thông tin tổng hợp từ các gói có liên quan dưới dạng luồng. Nhờ vậy, lượng dữ liệu cần xử lý giảm xuống [7]. Ví dụ về đặc trưng luồng gồm thời gian giữa các lần đến, thời lượng luồng, độ dài gói lớn nhất và các đặc trưng tương tự. Tuy nhiên, NIDS dựa trên luồng không thể phát hiện những cuộc tấn công phụ thuộc vào chi tiết bên trong từng gói, chẳng hạn nội dung tải trọng, vì các chi tiết này không được giữ lại khi xây dựng luồng [6].


Bên cạnh hai loại chính là NIDS dựa trên gói và NIDS dựa trên luồng, còn có loại thứ ba là NIDS lai, kết hợp đặc trưng dựa trên gói với đặc trưng dựa trên luồng. Phân loại tổng quát các giải pháp NIDS được trình bày trong Hình 1.



Hình 1. Phân loại ở mức cao các giải pháp NIDS: NIDS dựa trên gói kiểm tra từng gói riêng lẻ; NIDS dựa trên luồng phân tích thông tin tổng hợp thay vì từng gói; NIDS lai xem xét đồng thời dữ liệu của từng gói và dữ liệu luồng.

Quy trình chuẩn bị tập dữ liệu lưu lượng mạng, như minh họa trong Hình 2, bắt đầu bằng việc thu thập lưu lượng mạng thô. Quá trình này tạo ra dữ liệu mạng chứa đầy đủ tải trọng và thông tin phần đầu. Nếu mục tiêu là các đặc trưng dựa trên luồng, chỉ các đặc trưng luồng được tổng hợp từ các kết nối mạng mới được thu thập. Sau đó, nhà nghiên cứu thường chuyển đổi dữ liệu - gồm đặc trưng gói, đặc trưng luồng hoặc kết hợp cả hai - sang một dạng biểu diễn thích hợp để làm đầu vào cho mô hình ML/DL. Ở giai đoạn này, nhiều phương pháp

tiền xử lý có thể được áp dụng nhằm điều chỉnh dữ liệu thu thập được cho quá trình huấn luyện mô hình học máy.



Hình 2. Tổng quan các bước chuyển đổi dữ liệu lưu lượng mạng. Quy trình bắt đầu bằng thu thập dữ liệu lưu lượng thô, tiếp theo có thể xây dựng đặc trưng. Sau đó dữ liệu được chuyển đổi sang một định dạng biểu diễn cụ thể như dạng số, ảnh, chuỗi hoặc đồ thị. Tập dữ liệu đã chuyển đổi sẵn sàng được sử dụng để huấn luyện các mô hình NIDS.

Chuyển đổi dữ liệu lưu lượng mạng là một trong những bước tiền xử lý quan trọng nhất và có thể được thực hiện bằng nhiều phương pháp, tạo ra các dạng biểu diễn khác nhau. Chẳng hạn, lưu lượng mạng có thể được chuyển thành ảnh [8]-[10], mã hóa thành dữ liệu tuần tự hay chuỗi thời gian [11], hoặc biểu diễn dưới dạng đồ thị [12]. Nhờ những tiến bộ trong xử lý ngôn ngữ tự nhiên (NLP), một số phương pháp tấn công mạng còn biểu diễn dữ liệu mạng dưới dạng embedding byte bằng word2vec, như trong phương pháp Attack-GAN [13].

Để cải thiện hiệu năng và độ vững chắc của NIDS, nhiều công trình tập trung tăng cường tập dữ liệu bằng cách sinh gói tin tổng hợp thông qua mô hình sinh đối kháng. Trong quá trình này, việc lựa chọn kỹ thuật biểu diễn và chuyển đổi phù hợp cho gói tin mạng là rất quan trọng, nhằm bảo đảm gói tin tổng hợp có chất lượng và có ý nghĩa đối với NIDS. Có nhiều nghiên cứu sử dụng phương pháp sinh để tăng cường NIDS ở cả mức gói [9], [13], [14] và mức luồng [15]-[17]. Tuy cả hai hướng đều nhằm tạo dữ liệu mạng thực tế, lưu lượng được sinh thường không hợp lệ để thử nghiệm trong môi trường thật vì các nhiễu loạn áp dụng lên gói gốc không duy trì chức năng của quá trình truyền thông mạng [18].

Khi xây dựng một kỹ thuật chuyển đổi, nhìn chung cần duy trì chức năng của các gói trong phiên truyền thông ngay cả sau chuyển đổi. Điều này cho phép dữ liệu mạng tổng hợp được khôi phục thành gói mạng thực để thử nghiệm hệ thống ngoài thực tế, đồng thời cho phép đo độ vững chắc của NIDS trước các cuộc tấn công đối kháng sinh. Việc sinh tấn công đối kháng hoặc tạo biến thể của đặc trưng luồng để né tránh NIDS đặt ra nhiều thách thức [17] và phải tuân thủ các ràng buộc của miền an ninh. Gần đây, các nhà nghiên cứu đã cố gắng duy trì chức năng tấn công trong các ràng buộc này bằng GAN và các biến thể, chẳng hạn AttackGAN [13] ở mức gói và Flow-WGAN [19] ở mức luồng. Những tấn công này tạo môi trường kiểm thử có giá trị cho NIDS với điều kiện biểu diễn dữ liệu đối kháng có thể được dựng lại thành gói mạng thật.

Vì vậy, công trình này cũng xem xét hệ quả của những thuộc tính chuyển đổi như khả năng đảo ngược, kể cả khi thuộc tính này xuất hiện ngoài chủ ý trong giai đoạn phát triển NIDS. Dữ liệu đã chuyển đổi hoặc sinh tổng hợp cần phù hợp với thử nghiệm hệ thống thực để có thể triển khai trên nhiều thiết bị NIDS; tuy nhiên, khả năng đảo ngược phải được đánh giá cẩn thận nhằm tránh rủi ro an ninh ngoài ý muốn. Mặt khác, hiểu cách một

số phương pháp chuyển đổi có thể bị lợi dụng trong bối cảnh đối kháng sẽ giúp nhà nghiên cứu và nhà phát triển cải thiện chiến lược phòng thủ [20].

Dựa trên những tiến bộ này, nghiên cứu nhấn mạnh vai trò quyết định của chuyển đổi dữ liệu đối với hiệu năng NIDS. Chất lượng biểu diễn dữ liệu đưa vào mô hình ML/DL ảnh hưởng trực tiếp đến khả năng nắm bắt các mẫu phức tạp trong lưu lượng mạng. Các phương pháp chuyển đổi hiệu quả đặc biệt cần thiết trong mạng hiện đại, nơi lưu lượng tốc độ cao, gói mã hóa và nhiều loại tấn công đòi hỏi biểu diễn linh hoạt và hiệu quả. Nghiên cứu hướng đến cung cấp hiểu biết mới về mối quan hệ giữa phương thức chuyển đổi dữ liệu, hiệu năng mô hình và khả năng áp dụng hệ thống trong NIDS.

Các đóng góp chính của bài báo gồm:

- Cung cấp tổng quan về các phương thức chuyển đổi dữ liệu gói phục vụ học biểu diễn, tập trung vào tiền xử lý, mã hóa và khả năng đảo ngược.
- So sánh hiệu năng của một số chiến lược chuyển đổi gói tiên tiến cho NIDS.
- Phân tích thách thức, hạn chế và khuyến nghị nghiên cứu tương lai về xử lý dữ liệu trong NIDS.

Phần II trình bày sự khác biệt giữa nghiên cứu này và các công trình liên quan. Phần III mô tả phương pháp nghiên cứu. Phần IV tổng quan các tập dữ liệu NIDS. Phần V khảo sát các phương pháp chuyển đổi gói theo từng dạng biểu diễn. Phần VI trình bày thiết lập và kết quả thí nghiệm. Phần VII thảo luận các thách thức và vấn đề nghiên cứu mở. Cuối cùng, Phần VIII đưa ra kết luận.

II. CÔNG TRÌNH LIÊN QUAN

Do số lượng nghiên cứu về NIDS tăng nhanh, nhiều bài khảo sát đã xem xét các phương pháp và tập dữ liệu NIDS. Phần lớn khảo sát trước đây cung cấp tổng quan về hệ thống phát hiện xâm nhập và tập dữ liệu [1], [2], trong khi một số công trình tập trung vào đặc điểm và hạn chế của tập dữ liệu [21]-[23]. Một số khảo sát xem xét các tập dữ liệu cụ thể. Chẳng hạn, [24] tập trung vào CICIDS-2017 và CSE-CICIDS-2018. Công trình [25] phân tích 34 tập dữ liệu theo năm nhóm thuộc tính: thông tin chung, đánh giá, môi trường ghi nhận, khối lượng dữ liệu và bản chất dữ liệu. Các tập dữ liệu chuẩn được tổng quan trong [26], còn [27] khảo sát chi tiết loại tấn công trong 30 tập dữ liệu. Một nghiên cứu gần đây [28] thảo luận tập dữ liệu theo loại tấn công, nguồn dữ liệu, loại lưu lượng, đặc điểm lưu lượng, nhược điểm và các đặc trưng có sẵn.

Các công trình trên mô tả đặc điểm tập dữ liệu và sự phát triển của các nghiên cứu liên quan, nhưng không cung cấp chi tiết về phương thức chuyển đổi tập dữ liệu, tác động của chuyển đổi tới hiệu năng mô hình phát hiện, cũng như phương pháp và công cụ dùng để thực hiện chuyển đổi.

Nghiên cứu này khảo sát các tập dữ liệu phát hiện xâm nhập với trọng tâm là phương thức chuyển đổi và mã hóa đã áp dụng. Chuyển đổi dữ liệu ảnh hưởng lớn đến hiệu năng NIDS nhưng chỉ có ít công trình tập trung trực tiếp vào chủ đề này. Ví dụ, [29] khảo sát tác động của hai phép chuyển đổi dữ liệu, trong khi [30] đưa ra phân loại các phương thức chuyển đổi cho nhiều cách tiếp cận dựa trên CNN. Tuy gần với nghiên cứu này, [30] chỉ tập trung vào các phép chuyển đổi dựa trên điểm ảnh cho CNN. Biểu diễn số chỉ được đề cập ngắn gọn trong [26], còn biểu diễn chuỗi và đồ thị hầu như chưa được khảo sát. Nghiên cứu hiện tại đóng góp bằng cách phân tích toàn diện các phương thức chuyển đổi khác nhau, giúp nghiên cứu tương lai hiểu sâu hơn ảnh hưởng của chuyển đổi dữ liệu đối với NIDS.

Phần lớn bài tổng quan NIDS tập trung vào kỹ thuật ML/DL, còn kỹ thuật chuyển đổi dữ liệu chỉ được đề cập một phần. Theo hiểu biết của nhóm tác giả, chưa có khảo sát nào cung cấp thông tin chi tiết về phương thức chuyển đổi dữ liệu gói và ảnh hưởng của chúng tới hiệu năng mô hình NIDS. Bài báo này giải quyết khoảng trống đó bằng cách tổng hợp các phương thức chuyển đổi dữ liệu gói quan trọng nhất, đồng thời hỗ trợ nhà nghiên cứu lựa chọn kỹ thuật phù hợp với hệ thống và tập dữ liệu cụ thể.

Bảng 1. Tổng quan các bài khảo sát liên quan so với nghiên cứu này

Bảng 1. Tổng quan các bài khảo sát liên quan so với nghiên cứu này

Công trình	Trọng tâm	Đóng góp chính	Chuyển đổi dữ liệu
[1], [2]	Hệ thống phát hiện xâm nhập và tập dữ liệu	Tổng quan chung các phương pháp và tập dữ liệu NIDS	Không thảo luận
[21]-[23]	Đặc điểm và hạn chế của tập dữ liệu	Phân tích chi tiết hạn chế và thuộc tính tập dữ liệu	Không thảo luận
[24]	Các tập cụ thể: CICIDS-2017, CSE-CICIDS-2018	Phân tích sâu hai tập dữ liệu phổ biến	Không thảo luận
[25]	Phân tích 34 tập dữ liệu	Đánh giá toàn diện theo nhiều nhóm thuộc tính	Không thảo luận
[26]	Tập dữ liệu chuẩn	Tổng quan các tập chuẩn phổ biến	Chỉ đề cập ngắn gọn biểu diễn số
[27]	Loại tấn công trong 30 tập dữ liệu	Phân loại chi tiết các loại tấn công	Không thảo luận
[28]	Loại tấn công, nguồn dữ liệu, loại và đặc điểm lưu lượng, đặc trưng	Phân tích chi tiết thuộc tính và hạn chế tập dữ liệu	Không thảo luận
[29]	Ảnh hưởng của chuyển đổi dữ liệu tới mô hình phát hiện	Khảo sát hai phương pháp chuyển đổi	Hai phương pháp chuyển đổi
[30]	Phân loại chuyển đổi cho CNN	Tập trung vào chuyển đổi dựa trên điểm ảnh cho CNN	Biểu diễn dựa trên điểm ảnh
Nghiên cứu này	Phương thức chuyển đổi và ảnh hưởng tới NIDS	Khảo sát toàn diện phương thức chuyển đổi gói và tác động tới mô hình	Toàn diện: số, chuỗi, đồ thị và điểm ảnh


III. PHƯƠNG PHÁP NGHIÊN CỨU

Bài báo hướng đến cung cấp một khảo sát toàn diện về tài liệu liên quan đến chuyển đổi gói cho các tập dữ liệu NIDS. Nhóm tác giả tiến hành rà soát kỹ lưỡng các công trình khoa học mới nhất, bắt đầu từ các trang của nhà xuất bản như IEEE và ACM, sau đó mở rộng sang Scopus và Google Scholar để bao phủ nhiều nguồn hơn.

Do số lượng công bố về tập dữ liệu NIDS rất lớn, nghiên cứu thu hẹp phạm vi vào các bài được trích dẫn nhiều và những bài đề xuất ý tưởng chuyển đổi dữ liệu độc đáo. Danh sách ban đầu được xây dựng theo các tiêu chí:

1. Chuỗi tìm kiếm: "network intrusion detection" AND ("packet transformation" OR "packet representation" OR "data transformation" OR "data representation").
2. Các bài được công bố từ năm 2016 đến năm 2024.
3. Loại trừ bằng sáng chế và sách để tập trung vào bài tạp chí và hội nghị.

Sau khi lập danh sách ban đầu, nhóm tác giả đọc tóm tắt để bảo đảm mức độ liên quan. Các công trình chỉ tập trung vào ứng dụng cụ thể như IoT, thiết bị thông minh và phương tiện được loại bỏ. Tính mới của phương pháp chuyển đổi cũng được xem xét. Cuối cùng, 32 bài được chọn vào khảo sát.



Hình 3. Năm xuất bản của các nghiên cứu được đưa vào khảo sát. Phần lớn công trình là gần đây; 75% được công bố trong năm năm gần nhất. Một số bài cũ hơn được giữ lại để cung cấp góc nhìn toàn diện về sự phát triển của các phương pháp chuyển đổi theo thời gian.

IV. CÁC TẬP DỮ LIỆU NIDS

Phần này tổng hợp các tập dữ liệu phổ biến trong tài liệu và nêu bật định dạng cùng đặc trưng của chúng. Vì phân bố, chất lượng, số lượng và định dạng dữ liệu ảnh hưởng trực tiếp tới hiệu năng mô hình NIDS, cần xem xét kỹ phương thức biểu diễn dùng để huấn luyện mô hình.

Phần lớn tập dữ liệu NIDS công khai đã cũ và không biểu diễn lý tưởng lưu lượng bình thường lẫn độc hại [1]. Hạn chế này có thể được giảm nhẹ bằng cách tùy biến các phiên bản tập dữ liệu hiện có hoặc tiền xử lý chúng sang các dạng biểu diễn khác. Ví dụ, [31] xây dựng một bộ đặc trưng chuẩn dựa trên NetFlow cho các tập dữ liệu NIDS.

Nhiều tập dữ liệu truy cập mở không cung cấp gói thô mà chỉ cung cấp các đặc trưng mô tả luồng mạng, thường do vấn đề riêng tư [2]. Ngược lại, nhiều tập có gói thô lại không được gán nhãn, khiến nhà nghiên cứu phải tự xác định phương pháp gán nhãn và nhóm phân loại. Dù vậy, dữ liệu thô phù hợp với mạng nơ-ron sâu hiện đại vì các mô hình này có khả năng học đặc trưng trực tiếp từ dữ liệu [32]. Ngay cả khi có nhãn, phương pháp giám sát phụ thuộc vào nhãn chuẩn vẫn tốn thời gian, đòi hỏi chuyên môn miền và khó sử dụng với dữ liệu có tính phi dừng cao [33].

Một lựa chọn để xử lý thiếu nhãn là sử dụng phương pháp không giám sát nhằm tạo cụm theo giao thức hoặc địa chỉ IP. Tuy nhiên, cách này có thể làm tăng sai số tổng thể [34], bởi tập dữ liệu thiếu ngữ cảnh cần thiết để xác định nguồn hay sự kiện đã tạo ra lưu lượng. Các phân tích chuyên sâu về tập dữ liệu NIDS có thể tham khảo [2], [21] và [25].

Bảng 2. Tổng quan các tập dữ liệu NIDS phổ biến

Bảng 2. Tổng quan các tập dữ liệu NIDS phổ biến

Tập dữ liệu	Năm	Định dạng	Quy mô	Loại lưu lượng	Số lớp tấn công	Số đặc trưng	Có nhãn?
DARPA 98 [35]	1998	Tệp PCAP	10 GB	Mô phỏng	38	Không áp dụng	Không
KDD CUP 99 [36]	2000	Khác	5 triệu điểm dữ liệu	Mô phỏng	4	41	Có
LBNL [37]	2004	Gói tin	160 gói	Thực	1	Không áp dụng	Không
Kyoto 2006+ [38]	2006	Khác	93 triệu điểm dữ liệu	Thực	5	24	Có
NSL-KDD [39]	2009	Khác	148.514 điểm dữ liệu	Mô phỏng	4	41	Có
ISCX 2012 [40]	2012	Gói, luồng	2,4 triệu luồng	Mô phỏng	4	9	Có, ở mức luồng
SSENet-2014 [41]	2014	Khác	200.000 điểm dữ liệu	Mô phỏng	2	23	Có
UNSW-NB15 [42]	2015	Gói, luồng	2,54 triệu điểm dữ liệu	Mô phỏng	9	49	Có, ở mức luồng
CICIDS-2017 [43]	2017	Gói, luồng	2,8 triệu luồng	Mô phỏng	7	80	Có, ở mức luồng
CIDDS-001 [25]	2017	Luồng	32 triệu luồng	Tổng hợp	3	Không áp dụng	Có
CSE-CIC-IDS2018 [43]	2018	Gói, luồng, nhật ký	16,2 triệu luồng	Mô phỏng	7	80	Có, ở mức luồng
CICDDoS2019 [44]	2019	Luồng	294.627 luồng	Mô phỏng	10	80	Có
NF-UQ-NIDS-v2 [31]	2021	Luồng	50.822.680 luồng	Mô phỏng	10	43	Có
RoEduNet-SIMARGL2021 [45]	2021	Luồng	12,2 triệu luồng	Thực	3	44	Có

V. CÁC PHƯƠNG PHÁP CHUYỂN ĐỔI GÓI TIN

Phần này khảo sát định dạng dữ liệu mạng của các tập dữ liệu được sử dụng trong những nghiên cứu trước. Trọng tâm là loại dữ liệu được khai thác - gói thô, luồng, đặc trưng, tải trọng hoặc kết hợp các loại này - cùng với phương thức mã hóa. Nghiên cứu cũng xem xét liệu các phương pháp có sử dụng kỹ thuật chuyển đổi dữ liệu có khả năng đảo ngược hay không.

Có nhiều cách chuẩn bị lưu lượng để tạo đầu vào có giá trị cho mô hình ML/DL. Các công trình liên quan được chia thành bốn nhóm. Nhóm thứ nhất là biểu diễn vectơ số, được trình bày trong Phần V-A. Nhóm thứ hai gồm các nghiên cứu chuyển vectơ dữ liệu mạng thành ảnh, được trình bày trong V-B. Nhóm thứ ba sử dụng chuyển đổi dựa trên chuỗi, trình bày trong V-C. Cuối cùng, V-D trình bày biểu diễn dựa trên đồ thị.

A. CHUYỂN ĐỔI DẠNG SỐ

Phần này thảo luận các phương pháp chuyển đổi dạng số trên nhiều tập dữ liệu. Trước hết là phương pháp dựa trên gói, tiếp theo là phương pháp dựa trên luồng, và cuối cùng là phương pháp kết hợp cả hai.

1. Phương pháp dựa trên gói tin

Nhiều phương pháp đã được sử dụng để chuyển dữ liệu gói từ các tập dữ liệu khác nhau sang định dạng số nhằm xây dựng NIDS chính xác. Trong [46], nhóm tác giả chỉ sử dụng phần đầu TCP/UDP và tải trọng tầng vận chuyển, đồng thời loại bỏ một số trường như cổng và checksum. Các vectơ đặc trưng thu được được đưa vào mô hình 1D-CNN và mạng nơ-ron truyền thẳng (FNN) để phát hiện lưu lượng độc hại. Kết quả cho thấy CNN đạt độ chính xác tổng thể trên 98%.

Một số nghiên cứu khai thác nhiều chi tiết hơn. DeepMAL [47] sử dụng cả gói thô và luồng thô; 1.024 byte đầu tiên của tải trọng được dùng làm đầu vào để phân biệt dữ liệu lành tính và độc hại. Mô hình kết hợp 1D-CNN với LSTM; trên tập CTU, độ chính xác phân loại nhị phân lần lượt đạt 77,6% đối với dữ liệu độc hại và 76,5% đối với dữ liệu lành tính.

Công trình [34] nghiên cứu quá trình gán nhãn dữ liệu gói thô. Tải trọng được chuyển sang dữ liệu theo byte bằng một vectơ đặc trưng tổng quát, không phụ thuộc cấu trúc giao thức. DNN và CNN-LSTM được dùng để đánh giá. Kết quả cho thấy vectơ đặc trưng trích từ PCAP hoạt động tốt với gần như mọi mô hình so với tệp CSV đã tiền xử lý.

Trong [48], các tác giả sử dụng trực tiếp dòng byte đến, không cần bước tiền xử lý, để tạo gói được vectơ hóa có kích thước 1.300 byte. Gói sau đó được gán nhãn lành tính hoặc độc hại. Vectơ một chiều được đưa vào 1D-CNN để huấn luyện và kiểm thử trên USTC-TFC2016.

2. Phương pháp dựa trên luồng

So với gói thô, phân tích dựa trên luồng cung cấp một góc nhìn khác. Dữ liệu luồng chủ yếu là số, nhưng vẫn có những trường định danh như địa chỉ IP và số cổng. Vì vậy, các trường này phải được chuyển đổi để có thể sử dụng cùng các thuộc tính số khác.

Trong [49], các đặc trưng phi số được mã hóa one-hot để toàn bộ dữ liệu trở thành giá trị số. Nghiên cứu sử dụng học ít mẫu, chỉ dùng dưới 1% tập con KDDTrain+ của NSL-KDD để huấn luyện, nhưng đạt 92,34% trên KDD-Test+ và 85,75% trên KDD-Test-21. OHE cũng được dùng trong [50]. Tuy nhiên, nhóm tác giả trước hết

chuyển lưu lượng thô thành dữ liệu dạng bảng, mỗi hàng là một vectơ đặc trưng của một mẫu, sau đó mới áp dụng OHE cho các trường văn bản.

Công trình [6] cải thiện phát hiện tấn công ICMPv6-DDoS bằng một tập đặc trưng luồng mở rộng. Quy trình giảm đặc trưng theo tổ hợp chọn ra 16 đặc trưng tốt nhất, gồm 11 đặc trưng cơ bản và 5 đặc trưng tăng cường. Nhiều bộ phân loại được dùng để đánh giá, đạt độ chính xác từ 98,53% đến 99,99%.

FlowTransformer [5] chuyển dữ liệu luồng sang định dạng phù hợp với transformer. Bước mã hóa đầu vào biến các bản ghi luồng gồm trường số và trường phân loại thành vectơ đặc trưng có độ dài cố định. Các vectơ được xử lý bởi khối transformer - encoder hoặc decoder - rồi chuyển sang mô hình cuối để nhận diện lưu lượng độc hại.

3. Phương pháp lai

Một số nghiên cứu sử dụng đồng thời dữ liệu gói và luồng để tận dụng ưu điểm của cả hai. Trong [3], một mô hình lai trên UNSW-NB15 sử dụng kỹ thuật giảm đặc trưng và hai mô hình LSTM riêng: mô hình dựa trên luồng cho phân loại nhị phân và mô hình dựa trên gói cho phân loại đa lớp.

Gần đây, [51] đề xuất IDS lai nhiều giai đoạn. Dữ liệu gói và luồng được tiền xử lý, bao gồm chuyển đổi nhãn, rồi đưa vào một tổ hợp bộ phân loại. Nhiều thuật toán phân loại nâng cao được triển khai ở các tầng phát hiện khác nhau dựa trên thống kê lưu lượng đầu vào. Mô hình được đánh giá trên NSL-KDD, ISCX-IDS và UNSW-NB15.

Bảng 3. Các phương pháp NIDS sử dụng biểu diễn vectơ số

Bảng 3. Các phương pháp NIDS sử dụng biểu diễn vectơ số

Hướng NIDS	Tập dữ liệu	Công trình	Năm	Nhiệm vụ	Mô hình	Dữ liệu sử dụng	Độ chính xác	Có thể đảo ngược?
Gói	UNSW-NB15	[46]	2021	Nhị phân	1D-CNN, FNN	Phân đầu TCP/UDP bỏ trường cổng, checksum và tải trọng	98,99%	Không; nhiều trường bị loại bỏ
Gói	USTC-TFC2016	[48]	2018	Nhị phân	1D-CNN	1.300 byte	70% TPR	Không; chỉ giữ 1.300 byte
Gói	CTU-13	[47]	2020	Nhị phân, đa lớp	1D-CNN, LSTM	1.024 byte	77,6%; 76,5%	Không; chỉ giữ 1.024 byte, có cắt và đệm
Gói	UNSW-NB15, CICIDS-2017	[34]	2022	Đa lớp	1D-CNN-LSTM	TTL, tổng độ dài, giao thức	F1 = 69%	Không; chỉ giữ bốn trường phân đầu ngoài tải trọng
Luồng	NSL-KDD	[49]	2020	Nhị phân, đa lớp	DNN, 1D-CNN	40 thuộc tính	92,34%; 92,33%	Không; dùng giảm đặc trưng
Luồng	DDoS dựa trên ICMPv6	[6]	2022	Nhị phân	DT, Naive Bayes, KNN, NN, SVM, RFT	9 đặc trưng	Trung bình 99,38%	Không; dùng giảm đặc trưng
Luồng	NSL-KDD, UNSW-NB15, CSE-CIC-IDS2018	[5]	2024	Nhị phân	Transformer với nhiều đầu phân loại	Không nêu	F1: 98%; 90,45%; 97,05%	Không; dữ liệu được mã hóa
Luồng	UNSW-NB15	[50]	2023	Nhị phân	TabNet + SRU	Không nêu	99,23%	Không; một số đặc trưng bị loại
Lai	UNSW-NB15	[3]	2020	Nhị phân, đa lớp	Bi-LSTM	Gói: 5 đặc trưng; luồng: 8 đặc trưng	96%; 76%	Không; có giảm đặc trưng
Lai	NSL-KDD, ISCX-IDS2012, UNSW-NB15	[51]	2023	Nhị phân	USVM, HH-ELM, RSO-SCNN	Tập dữ liệu thô	99,26%; 98,55%; 99,33%	Không; có trích đặc trưng và lấy mẫu quá mức

B. CHUYỂN ĐỔI DỰA TRÊN ĐIỂM ẢNH

Phần này trình bày các kỹ thuật chuyển đổi dữ liệu sang điểm ảnh cho dữ liệu gói, dữ liệu luồng và dữ liệu lai.

1. Phương pháp dựa trên gói tin

Nhiều nhóm nghiên cứu chuyển lưu lượng mạng thành ảnh để phân tích tốt hơn tính phức tạp của dữ liệu. CNN ngày càng được sử dụng để học đặc trưng không gian [52], trong đó các byte mạng được biểu diễn như điểm ảnh.

Thuật toán P-Zigzag trong [29] chuyển một gói thô 1.518 byte thành ảnh 64 x 64. Dữ liệu được điền theo đường zigzag nhằm giữ nguyên thông tin gốc mà không mất mát. Thí nghiệm kết hợp UNSW-NB15 và CICIDS-2017, sử dụng mô hình IDS nhiều tầng dựa trên CNN và gcForest.

Một số công trình khác chuyển dữ liệu gói thành ảnh RGB [53], [54]. Phương pháp [53] tạo các ảnh 2D bằng nhiều bộ biến đổi ảnh như t-SNE và UMAP. Các ảnh xám sau đó được ghép thành ảnh màu RGB ba kênh để đưa vào mô hình học sâu.

Trong [54], ảnh tuần tự được tạo từ dữ liệu gói. Trước hết, đặc trưng của phần đầu và tải trọng được trích xuất, đổi sang giá trị thập phân và sắp xếp thành ma trận, trong đó mỗi hàng biểu diễn một gói theo thứ tự. Ma trận được chuyển thành ảnh RGB: gói theo chiều đi được lưu ở kênh R, gói theo chiều về ở kênh G, còn kênh B được đệm bằng 0.

2. Phương pháp dựa trên luồng

Nhiều kỹ thuật chuyển dữ liệu luồng thành ảnh đã được đề xuất để sử dụng với CNN. Công trình [55] đưa ra phương pháp mã hóa tương tự RGB. Dữ liệu luồng được chuyển thành mã hóa $N \times N$ dựa trên $(10 \times N + M)/8$ điểm ảnh, trong đó N là số đặc trưng số và M là số đặc trưng định danh. Mỗi đặc trưng được chuyển thành số nhị phân 10 chữ số, sau đó tạo ảnh 12 x 12 có đệm để làm đầu vào CNN.

Trong [56], 41 đặc trưng của NSL-KDD - gồm số nguyên, số thực, biến phân loại và biến nhị phân - được chuyển thành vectơ nhị phân rồi biến thành ảnh xám.

Các công trình [15], [57], [58] cũng chuyển dữ liệu luồng thành ảnh xám. Trong [57], lưu lượng thô được chia thành luồng ở mức phiên có giao tiếp hai chiều. Mỗi luồng được chuyển thành dòng 784 byte rồi định hình lại thành ảnh xám 28 x 28, mỗi điểm ảnh tương ứng một byte. Công trình [58] dùng ánh xạ đường cong Hilbert để chuyển dữ liệu luồng 1D sang tọa độ ảnh 2D, duy trì tính cục bộ của dữ liệu. Mỗi luồng được ánh xạ theo thời gian và ảnh xám biểu diễn đặc trưng của một luồng. Trong [15], vectơ đặc trưng 1D được ánh xạ thành ảnh 2D; mất cân bằng dữ liệu được xử lý bằng tăng cường dữ liệu với GAN.

Ngoài cách ánh xạ trực tiếp điểm ảnh, [59] dùng biến đổi Fourier thời gian ngắn (STFT) để chuyển dữ liệu luồng thành ảnh phổ, biểu diễn thông tin tần số và năng lượng, rồi đưa vào CNN phát hiện bất thường. Công trình [10] chuyển từng mẫu CSE-CIC-IDS2018 thành ảnh mã QR 1.410 x 1.410 với độ sâu một bit, sau đó sử dụng MobileNetV2 và ShuffleNet.

3. Phương pháp lai

HAST-IDS [52] kết hợp ảnh gói với dữ liệu chuỗi luồng để học trực tiếp các mẫu không gian - thời gian phân cấp từ lưu lượng thô. Dữ liệu gói được dùng để học đặc trưng không gian; dữ liệu luồng được dùng để học mẫu thời gian. Gói được chuyển thành ảnh bằng OHE và đưa vào CNN, còn chuỗi gói được đưa vào LSTM. Cách làm này tạo đặc trưng không gian - thời gian chính xác hơn.

Trong [60], các tác giả kết hợp mô hình 1D-CNN và 2D-CNN trên tệp PCAP và đặc trưng nghiệp vụ. Độ dài xử lý trung bình của mỗi luồng được đặt là 784 byte. Byte thập lục phân của luồng được chuyển đồng thời thành vectơ 1D và ma trận 2D 28 x 28, rồi đưa tương ứng vào 1D-CNN và 2D-CNN.

Bảng 4. Các phương pháp NIDS sử dụng biểu diễn dựa trên điểm ảnh

Bảng 4. Các phương pháp NIDS sử dụng biểu diễn dựa trên điểm ảnh

Hướng NIDS	Tập dữ liệu	Công trình	Năm	Nhiệm vụ	Mô hình	Dữ liệu sử dụng	Kết quả	Có thể đảo ngược?
Gói	NBC: UNSW-NB15 + CICIDS-2017	[29]	2019	Đa lớp	GoogLeNetNP, gcForest	Tải trọng	99,24%	Không; phân đầu bị loại
Gói	CIC-IDS2018	[54]	2024	Đa lớp	2D-CNN	Toàn bộ gói	98,78%	Không; một số đặc trưng bị loại hoặc mã hóa
Gói	ISCX2012, CSE-CIC-IDS2018	[53]	2023	Đa lớp	Image Transformer + 2D-CNN	80 đặc trưng	95,6%; 95,5%	Không; sử dụng giảm chiều
Luồng	NSL-KDD	[56]	2017	Nhị phân	ResNet50	41 đặc trưng	79,14%	Không; chỉ dùng một tập con đặc trưng
Luồng	CICIDS-2017	[55]	2018	Đa lớp	GoogLeNet	77 đặc trưng	F1 = 88-89%	Không; có đệm và lượng tử hóa
Luồng	KDD Cup 1999, UNSW-NB15, CICIDS-2017, AAGM17	[15]	2021	Nhị phân	2D-CNN	Theo [15]	93,29%; 89,73%; 98,49%; 88,03%	Không; có giảm chiều
Luồng	CSE-CIC-IDS2018	[10]	2023	Đa lớp	MobileNetV2 + ShuffleNet	80 thuộc tính thống kê	95,89%	Không; có chọn đặc trưng
Luồng	CIC-IDS2017	[59]	2021	Nhị phân, đa lớp	2D-CNN	78 đặc trưng	99,35%; 98,76%	Không; một số trường bị loại hoặc mã hóa
Luồng	USTC-TFC2016	[57]	2023	Đa lớp	CNN-SE-net	Dữ liệu phiên, cửa sổ chặn	F1 = 98,9%	Không; dữ liệu được sắp xếp lại và mã hóa
Luồng	CIC-IDS2017, NSL-KDD	[58]	2024	Nhị phân	2D-CNN	Loại bỏ đặc trưng ít quan trọng	F1 = 93,05%; 83,46%	Không; dữ liệu được chuẩn hóa và mã hóa
Lai	UNSW-NB15, VPN2016, CICIDS-2012, CIC2017	[60]	2021	Đa lớp	1D-CNN, 2D-CNN	Phân đầu TCP, tải trọng, đặc trưng nghiệp vụ	99%	Không; chỉ giữ 784 byte
Lai	SCX2012	[52]	2018	Đa lớp	2D-CNN, LSTM	'n' byte đầu của luồng	99,89%	Không; chỉ giữ một số byte nhất định

C. CHUYỂN ĐỔI DỰA TRÊN CHUỖI

Các phương pháp dựa trên chuỗi được thúc đẩy bởi sự phụ thuộc thời gian trong lưu lượng mạng. Phần này trình bày chuyển đổi chuỗi cho dữ liệu gói, dữ liệu luồng và phương pháp lai.

1. Phương pháp dựa trên gói tin

Một số nghiên cứu sử dụng embedding dữ liệu tuần tự làm đầu vào. Attack-GAN [13] dùng toàn bộ gói, trong đó mỗi byte được biểu diễn bằng embedding số 32 chiều. Byte trong gói mạng được xem như token trong một chuỗi, còn các byte do bộ sinh tạo ra biểu diễn trạng thái hiện tại. Kết quả phụ thuộc vào cách embedding một byte hoặc hai byte. Với embedding hai byte, tỷ lệ thất bại của tấn công giảm dần so với embedding một byte. Do yêu cầu đầu vào, nhóm tác giả phải cố định độ dài chuỗi byte độc hại.

Các công trình [61], [62] dùng gói riêng lẻ để tạo vectơ luồng. Trong [61], dữ liệu gói được chuyển thành vectơ ở mức byte, sau đó đi qua Restricted Boltzmann Machine nhiều tầng để trích vectơ đặc trưng có độ dài cố định cho từng gói. Các đặc trưng được đưa vào RNN để mô hình hóa quan hệ thời gian giữa các gói và tạo biểu diễn ở mức luồng.

RUIDS [62] là một hệ thống phát hiện xâm nhập không giám sát vững chắc dựa trên học tự giám sát với transformer. Dữ liệu gói được chuyển thành chuỗi thời gian bằng cách chia thành các đối tượng dữ liệu theo dấu thời gian, sau đó áp dụng lấy mẫu che mặt nạ và các phép biến đổi có thể học. Transformer nắm bắt quan hệ tuần tự giữa các đối tượng còn lại.

2. Phương pháp dựa trên luồng

Trong chuyển đổi chuỗi ở mức luồng, mục tiêu là hiểu hành vi lưu lượng của người dùng theo thời gian. Công trình [11] thiết kế RNN có cơ chế attention để học đặc trưng thời gian hằng ngày của từng người dùng trên tập CERT [63], sau đó áp dụng để phát hiện lưu lượng mã độc. Vì dữ liệu không có nhãn, k-means được dùng để nhóm những người dùng có mẫu dữ liệu tương tự. Quá trình phân cụm hỗ trợ lọc bất thường do các điểm tương đồng thường được gom cùng nhau. Mô hình được huấn luyện trên hai tập lưu lượng thô và đạt precision cùng recall khoảng 60%, cao hơn các phương pháp cơ sở.

Công trình [64] sử dụng ký tự thay vì từ, xây dựng mô hình sequence-to-sequence có attention để học embedding của dữ liệu mạng lặp lại. Phương pháp được áp dụng trên hai phần của CTU-13, sử dụng các ký hiệu của một mô hình hành vi. Mỗi ký hiệu của kết nối được biểu diễn bằng vectơ nhị phân kích thước 50, tương tự OHE. Ma trận thu được được đưa lần lượt từng hàng vào LSTM.

3. Phương pháp lại

Phương pháp [65] sử dụng học chuyển giao dựa trên transformer để trích embedding ngữ cảnh từ dữ liệu gói và luồng kết hợp, qua đó mô hình hóa quan hệ phức tạp giữa hai loại dữ liệu. BERT làm nổi bật các mẫu thời gian và quan hệ, tạo biểu diễn lưu lượng vững chắc. Các embedding tiếp tục được xử lý qua chuỗi CNN-LSTM: lớp tích chập trích đặc trưng từ mẫu luồng, còn LSTM nắm bắt phụ thuộc tuần tự, giúp mô hình hóa chính xác hành vi mạng và cải thiện phát hiện xâm nhập.

Bảng 5. Các phương pháp NIDS sử dụng biểu diễn dữ liệu tuần tự

Bảng 5. Các phương pháp NIDS sử dụng biểu diễn dữ liệu tuần tự

Hướng NIDS	Tập dữ liệu	Công trình	Năm	Nhiệm vụ	Mô hình	Dữ liệu sử dụng	Kết quả	Có thể đảo ngược?
Gói	CTU-13	[13]	2021	Nhị phân	LSTM-GAN	Toàn bộ gói	89-98%	Có; dữ liệu thô được chuyển đổi không thay đổi nội dung
Gói	ISCX-2012, DARPA-1998	[61]	2018	Đa lớp	RNN với RPM	Toàn bộ gói	99,73%; 99,3%	Không; dữ liệu gói được tái cấu trúc
Gói	UNSW-NB15	[62]	2023	Nhị phân	Transformer	Toàn bộ gói	92,62%	Không; có sử dụng encoder
Luồng	CTU-13	[64]	2016	Nhị phân: botnet/khác	LSTM	Kích thước, thời lượng và tính chu kỳ của luồng	ADR = 97,96%	Không; kết nối bị rút về 10 trạng thái và chỉ giữ vài đặc trưng
Luồng	NETFLOW, CERT	[11]	2020	Nhị phân	LSTM	NETFLOW: số đếm, bitmap, top-K; CERT: thông tin tăng ứng dụng và hồ sơ người dùng	Không nêu	Không; dữ liệu được phân cụm và lọc đặc trưng
Lai	UNSW-NB15, CIC-IDS2017, NSL-KDD	[65]	2024	Đa lớp	BERT + CNN-LSTM	Không nêu	Không cung cấp điểm tổng thể	Không; đặc trưng được mã hóa

D. CHUYỂN ĐỔI DỮ LIỆU TRÊN ĐỒ THỊ

Kỹ thuật chuyển đổi đồ thị cũng được áp dụng cho lưu lượng mạng trong IDS [66]. Tuy có ít công trình hơn so với biểu diễn số và điểm ảnh, đồ thị hữu ích trong việc nắm bắt mẫu không gian và thời gian. Phần này trình bày biểu diễn đồ thị cho dữ liệu gói và dữ liệu luồng.

1. Phương pháp dựa trên gói tin

Nghiên cứu biểu diễn đồ thị chủ yếu tập trung vào dữ liệu luồng. Chỉ một công trình trong khảo sát chuyển gói thành đồ thị [12]. Nhóm tác giả đề xuất packet2vec để trích các thuộc tính lân cận cục bộ chính xác của gói từ biểu diễn đồ thị. Đặc trưng lân cận này cùng thuộc tính gốc của gói được đưa vào IDS dựa trên deep autoencoder.

2. Phương pháp dựa trên luồng

Dữ liệu luồng phù hợp tự nhiên với biểu diễn đồ thị và có thể được xây dựng theo nhiều cách. AddGraph [67] tích hợp đặc trưng cấu trúc, nội dung và thời gian. Mô hình phát hiện bất thường dựa trên GNN kết hợp đặc trưng nội dung và cấu trúc.

Trong [68], phương pháp sinh line graph [69] chuyển dữ liệu luồng thành đồ thị, trong đó mỗi nút là một luồng mạng và cạnh nối các nút có chung một đầu nút. Đồ thị sau đó được đưa vào graph autoencoder để học embedding gọn và vững chắc trước khi huấn luyện mô hình ML.

Công trình [70] xem mỗi phần dữ liệu lưu lượng là một nút. Affinity Propagation được dùng để chọn nút đại diện, tạo cấu trúc tiến hóa cục bộ. Các nút được nối theo quan hệ thời gian thành cấu trúc đồ thị toàn cục, qua đó nắm bắt cả mẫu cục bộ lẫn toàn cục và nhấn mạnh sự tiến triển theo thời gian của tấn công.

DMTR [71] biểu diễn dữ liệu luồng thành đồ thị bằng Dynamic Multi-scale Topological Representation. Một thuật toán Mapper cải tiến chuyển dữ liệu luồng thành cấu trúc tô pô. Trước hết, hàm lọc như UMAP chiếu dữ liệu nhiều chiều xuống không gian thấp chiều, rồi chia thành các khoảng hoặc bin chồng lấp. Phân cụm được thực hiện trong từng bin, và đồ thị tô pô được tạo bằng cách nối những cụm có chung điểm dữ liệu. Nhiều lăng kính tô pô được sử dụng để nắm bắt cấu trúc ở nhiều thang, giữ lại cả mẫu chi tiết và tổng quát. Phép group shuffle operation cập nhật biểu diễn động bằng cách trộn dữ liệu mới với một phần dữ liệu hiện có, duy trì hiệu quả tính toán khi lưu lượng thay đổi.

Bảng 6. Các phương pháp NIDS sử dụng biểu diễn đồ thị

Bảng 6. Các phương pháp NIDS sử dụng biểu diễn đồ thị


Hướng NIDS	Tập dữ liệu	Công trình	Năm	Nhiệm vụ	Mô hình	Dữ liệu sử dụng	Kết quả	Có thể đảo ngược?
Gói	ISCX2012	[12]	2019	Đa lớp	Autoencoder	Đặc trưng gói + đặc trưng lân cận cục bộ	94,7%	Không; biểu diễn dữ liệu bị thay đổi
Luồng	CTU-13	[68]	2023	Đa lớp	GCN	Thời lượng, tổng số gói, tổng byte, giao thức, loại cổng...	98,2%	Không; dữ liệu được lọc
Luồng	UNSW-NB15	[70]	2023	Nhi phân	Temporal-Gated GNN	Dữ liệu mạng thô	95,14%	Có; sử dụng dữ liệu mạng thô
Luồng	UNSW-NB15, CIC-IDS2017	[71]	2023	Đa lớp	DMTR	Không nêu	99,97%; 99,87%	Không; một số dữ liệu được sửa đổi hoặc mã hóa

E. THẢO LUẬN TÀI LIỆU

Từ các công trình được khảo sát có thể rút ra một số kết luận. Biểu diễn dựa trên điểm ảnh phổ biến nhất với 12 bài, tiếp theo là biểu diễn số với 10 bài, biểu diễn chuỗi với 6 bài và biểu diễn đồ thị với 4 bài.

NIDS dựa trên luồng được dùng nhiều nhất, xuất hiện trong 16 bài: 7 bài điểm ảnh, 4 bài số, 2 bài chuỗi và 3 bài đồ thị. NIDS dựa trên gói xuất hiện trong 11 bài: 3 bài điểm ảnh, 4 bài số, 3 bài chuỗi và 1 bài đồ thị. Đối với NIDS lai, biểu diễn số và điểm ảnh mỗi loại xuất hiện trong hai bài, biểu diễn chuỗi xuất hiện trong một bài. NIDS dựa trên luồng được quan tâm vì cần ít tài nguyên và phù hợp với ML nhờ bản chất vectơ hóa của

luồng [72]. Tuy nhiên, phương pháp này kém hiệu quả hơn gói tin khi tấn công nằm trong tải trọng [34]. Xét sự phức tạp và đa dạng của lưu lượng, một số nghiên cứu đề xuất hướng lai như một giải pháp tiềm năng.



Transformation	Approaches	Papers
Pixel	Packet=3	[29], [53], [54]
	Flow=7	[10], [15], [55]–[59]
	Hybrid=2	[52], [60]
Numerical	Packet=4	[34], [46]–[48]
	Flow=4	[5], [6], [49], [50]
	Hybrid=2	[3], [51]
Sequence	Packet=3	[13], [61], [62]
	Flow=2	[11], [64]
	Hybrid=1	[65]
Graph	Packet=1	[12]
	Flow=3	[68], [70], [71]

Hình 4. Phân bố các dạng chuyển đổi và hướng NIDS trong các nghiên cứu. Chuyển đổi điểm ảnh chiếm 37,5%, đặc biệt phổ biến với dữ liệu luồng. Chuyển đổi số chiếm 31,2% và là phương pháp thường dùng nhất cho dữ liệu gói. Chuyển đổi chuỗi chiếm 18,8%, còn đồ thị chiếm 12,5% và chủ yếu được áp dụng cho dữ liệu luồng.

Sáu tập dữ liệu được sử dụng lặp lại nhiều lần. UNSW-NB15 phổ biến nhất, xuất hiện trong 12 bài [3], [5], [15], [34], [46], [50], [51], [60], [62], [65], [70], [71]. CIC-IDS2017 được dùng trong tám bài [15], [34], [55], [58]-[60], [65], [71]. NSL-KDD xuất hiện trong sáu bài [5], [49], [51], [56], [58], [65]. ISCX2012 [12], [51], [52], [61], CTU-13 [13], [47], [64], [68] và CSE-CIC-IDS2018 [5], [10], [53], [54] mỗi tập xuất hiện trong bốn bài. Các tập dữ liệu phục vụ cả phân loại đa lớp theo loại tấn công và phân loại nhị phân lãnh tính/độc hại.

Khi so sánh các công trình sử dụng cùng tập dữ liệu và cùng nhiệm vụ, phương pháp số có hiệu năng nổi bật trong phân loại nhị phân trên bốn tập dữ liệu, đặc biệt khi kết hợp với dữ liệu luồng hoặc dữ liệu lai. Ngược lại, biểu diễn đồ thị kết hợp với luồng cho kết quả đa lớp tốt nhất trên ba tập dữ liệu, dù chỉ có bốn nghiên cứu đồ thị. Biểu diễn điểm ảnh có kết quả biến thiên, tốt nhất khi kết hợp với dữ liệu gói hoặc dữ liệu lai. Biểu diễn chuỗi đứng đầu trong một trường hợp phân loại nhị phân trên dữ liệu gói.

Xét theo tập dữ liệu, CIC-IDS2017 liên tục cho kết quả tốt nhất ở cả nhiệm vụ nhị phân và đa lớp khi sử dụng dữ liệu luồng, dù phương pháp chuyển đổi khác nhau. ISCX2012 đạt kết quả tốt nhất với dữ liệu lai. NSL-KDD hoạt động tốt hơn với biểu diễn số, không phụ thuộc hướng NIDS. Sự khác biệt cho thấy mỗi tập dữ liệu phản ứng khác nhau với cùng phương pháp, do cấu trúc, thông tin được ghi nhận và thiết lập thu thập lưu lượng.

Bảng 7. Hướng tiếp cận và phép chuyển đổi cho kết quả tốt nhất theo nhiệm vụ và tập dữ liệu

Bảng 7. Hướng tiếp cận và phép chuyển đổi cho kết quả tốt nhất theo nhiệm vụ và tập dữ

Tập dữ liệu	Nhiệm vụ	Hướng NIDS tốt nhất	Chuyển đổi tốt nhất	Công trình
CICIDS-2017	Nhị phân	Luồng	Điểm ảnh	[59]
CICIDS-2017	Đa lớp	Luồng	Đồ thị	[71]
CSE-CIC-IDS2018	Nhị phân	Luồng	Số	[5]
CSE-CIC-IDS2018	Đa lớp	Gói	Điểm ảnh	[54]
CTU-13	Nhị phân	Gói	Chuỗi	[13]
CTU-13	Đa lớp	Luồng	Đồ thị	[68]
ISCX-2012	Nhị phân	Lai	Số	[51]
ISCX-2012	Đa lớp	Lai	Điểm ảnh	[52]
NSL-KDD	Nhị phân	Lai	Số	[51]
NSL-KDD	Đa lớp	Luồng	Số	[49]
UNSW-NB15	Nhị phân	Lai	Số	[51]
UNSW-NB15	Đa lớp	Luồng	Đồ thị	[71]

Nhiều thuật toán chuyển đổi được sử dụng lặp lại. OHE xuất hiện trong mười nghiên cứu để hỗ trợ chuyển đổi số [3], [5], [49], [50], điểm ảnh [15], [52], [55], [56], chuỗi [62] và đồ thị [71]. Trong một số trường hợp, OHE là bước đầu chuyển dữ liệu phân loại sang số rồi tiếp tục chuyển sang biểu diễn khác, như [52]. Trong trường hợp khác, OHE là phương pháp chuyển đổi chính, như [3].

Word2Vec và Packet2Vec mã hóa dữ liệu thành embedding nắm bắt quan hệ ngữ cảnh giữa các byte [13]. P-Zigzag chuyển lưu lượng thành biểu diễn 2D trong khi giữ lại thông tin gốc [29]. Thành phần quan trọng của P-Zigzag là biến đổi cosine rồi rạc ngược, dùng để tạo ảnh xám từ bản đồ miền tần số. Theo [29], P-Zigzag vượt

OHE về cả hiệu quả và hiệu năng: thời gian chuyển gói nhanh hơn 3 lần, thời gian huấn luyện nhanh hơn trên 5 lần và kiểm thử nhanh hơn khoảng 1,2 lần.

STFT và đường cong Hilbert tạo ảnh có thông tin thời gian. STFT chuyển tín hiệu miền thời gian thành ảnh phổ [59], trong khi đường cong Hilbert ánh xạ dữ liệu luồng sang ảnh 2D [58]. Các kỹ thuật giảm chiều gồm t-SNE, PCA và UMAP. t-SNE và UMAP giảm chiều phi tuyến; PCA giảm chiều tuyến tính. Công trình [53] dùng cả ba rồi ghép kết quả thành ảnh RGB. t-SNE còn được dùng để trực quan hóa NETFLOW hỗ trợ phân cụm [11] và trong quy trình mã hóa ảnh [15]. UMAP được dùng trong [71] để chiếu dữ liệu nhiều chiều xuống không gian thấp chiều.

Bảng 8. Các thuật toán được dùng trong quá trình chuyển đổi dữ liệu

Bảng 8. Các thuật toán được dùng trong quá trình chuyển đổi dữ liệu

Nhóm	Thuật toán	Công trình	Mục đích
Chuyển đổi dữ liệu	One-hot encoding	[3], [5], [15], [49], [50], [52], [55], [56], [62], [71]	Mã hóa biến phân loại thành vectơ nhị phân số
Chuyển đổi dữ liệu	Word2Vec	[13]	Ánh xạ byte gói thành biểu diễn vectơ nhiều chiều
Chuyển đổi dữ liệu	Packet2Vec	[12]	Trích đặc trưng lân cận cục bộ của gói để tiến xử lý
Chuyển đổi dữ liệu	P-Zigzag	[29]	Mã hóa lưu lượng thành ảnh xám 2D phục vụ học biểu diễn
Chuyển đổi dữ liệu	Biến đổi cosine rời rạc ngược	[29]	Chuyển dữ liệu miền tần số thành ảnh xám
Chuyển đổi dữ liệu	STFT	[59]	Chuyển tín hiệu miền thời gian thành ảnh phổ
Chuyển đổi dữ liệu	Đường cong Hilbert	[58]	Ánh xạ luồng mạng thành ảnh 2D theo tọa độ Hilbert
Giảm chiều	t-SNE	[11], [15], [53]	Giảm chiều phi tuyến phục vụ trực quan hóa
Giảm chiều	PCA	[53]	Giảm chiều tuyến tính
Giảm chiều	UMAP	[53], [71]	Giảm chiều phi tuyến cho dữ liệu nhiều chiều

Sau chuyển đổi, dữ liệu được đưa vào nhiều mô hình huấn luyện và kiểm thử. CNN, đặc biệt 2D-CNN, được dùng rộng rãi với dữ liệu điểm ảnh. Một số kiến trúc chuyên biệt gồm GoogLeNet, ResNet50, MobileNetV2 và ShuffleNet. 1D-CNN chủ yếu được dùng với biểu diễn số.

Trong nhóm RNN, LSTM là mô hình phổ biến nhất và được dùng với cả bốn dạng chuyển đổi, hoặc để tăng cường học thông tin thời gian, hoặc làm mô hình chính. SRU được dùng trong [50] cùng cơ chế attention để

tìm liên kết tiềm ẩn trong lưu lượng. Các mô hình giám sát khác gồm GNN trong hai phương pháp đồ thị, TabNet cho dữ liệu bảng [50] và HH-ELM trong [51].

Phương pháp không giám sát được sử dụng dưới dạng mô hình sinh hoặc phân cụm. GAN, autoencoder và transformer xuất hiện thường xuyên. Autoencoder phổ biến nhất vì được áp dụng cho cả bốn dạng chuyển đổi, với nhiều encoder/decoder như CNN và RNN. Ba loại phân cụm được dùng, thường phối hợp với kỹ thuật khác. Các phương pháp đồ thị [70], [71] sử dụng phân cụm để hỗ trợ dựng đồ thị; [11] dùng phân cụm để phát hiện bất thường riêng cho từng cụm.

Bảng 9. Các mô hình sử dụng cho dữ liệu đã chuyển đổi

Bảng 9. Các mô hình sử dụng cho dữ liệu đã chuyển đổi

Nhóm	Mô hình	Dạng chuyển đổi	Công trình
CNN	2D-CNN	Điểm ảnh	[15], [53], [54], [59], [60]
CNN	1D-CNN	Điểm ảnh, số, chuỗi	Điểm ảnh: [60]; số: [34], [46]-[48]; chuỗi: [65]
CNN	GoogLeNet	Điểm ảnh	[29], [55], [56]
CNN	ResNet50	Điểm ảnh	[56]
CNN	MobileNetV2, ShuffleNet	Điểm ảnh	[10]
RNN	LSTM	Điểm ảnh, chuỗi, đồ thị, số	Điểm ảnh: [52], [57]; chuỗi: [11], [13], [64], [65]; đồ thị: [70]; số: [3], [34], [47]
RNN	SRU	Số	[50]
Mô hình sinh	GAN	Điểm ảnh, chuỗi	Điểm ảnh: [15]; chuỗi: [13]
Mô hình sinh	Autoencoder	Điểm ảnh, chuỗi, đồ thị, số	Điểm ảnh: [58]; chuỗi: [11]; đồ thị: [12], [68]; số: [5]
Mô hình sinh	RBM	Chuỗi	[13]
Mô hình sinh	Transformer	Chuỗi, số	Chuỗi: [11], [62], [65]; số: [5], [50]
Phân cụm	K-means	Chuỗi	[11]
Phân cụm	Affinity Propagation	Đồ thị	[70]
Phân cụm	DBSCAN	Đồ thị	[71]
Khác	TabNet	Số	[50]
Khác	HH-ELM	Số	[51]
Khác	GNN	Đồ thị	[68], [70]

Phân tích cho thấy phần lớn nghiên cứu không đánh giá rõ hệ quả của chuyển đổi dữ liệu. Nhiều quy trình gói chỉ trích một số trường và bỏ phần còn lại, hoặc cắt/dệm để vừa kích thước đầu vào ML/DL [30]. Cắt dữ liệu về độ dài cố định gây khó khăn cho chuyển đổi đảo ngược. Phần lớn phương pháp dựa trên gói không thể đảo ngược, làm phức tạp mô phỏng trên NIDS thực tế. Các phương pháp điểm ảnh - nhóm lớn nhất - thường đệm 0 để chuẩn hóa độ dài tải trọng hoặc gói, khiến việc khôi phục ngược trở nên bất khả thi.

Trong 32 công trình, chỉ hai nghiên cứu sử dụng dữ liệu mạng thô không thay đổi [13], [70]. Dù không vượt trội về hiệu năng, chúng chứng minh khả năng sử dụng dữ liệu thô trong NIDS mà không làm thay đổi đáng kể cấu trúc gốc. Tuy nhiên, dùng dữ liệu thô có thể gây rủi ro, như tăng khả năng NIDS bị khai thác hoặc làm lộ thông tin nhạy cảm. Vì vậy cần đánh giá và có chiến lược giảm thiểu phù hợp.

VI. THÍ NGHIỆM CHUYỂN ĐỔI DỮ LIỆU

Phần này đánh giá các dạng biểu diễn được khảo sát trong một nhiệm vụ phân loại lưu lượng mạng đa lớp, tập trung so sánh hiệu quả tính toán. Bảng 7 đã nêu phép chuyển đổi tốt nhất cho từng tập dữ liệu theo hiệu năng phát hiện. Tuy nhiên, việc so sánh hiệu quả giữa các nghiên cứu khó thực hiện do thiết lập thí nghiệm khác nhau. Vì vậy, nhóm tác giả chuẩn hóa môi trường tính toán cho tất cả dạng biểu diễn nhằm so sánh thời gian huấn luyện và kiểm thử.

Toàn bộ thí nghiệm được chạy trên Ubuntu 20.04 với GPU NVIDIA RTX 4090 chuyên dụng có 24 GB bộ nhớ GDDR6X.

A. TẬP DỮ LIỆU VÀ TIỀN XỬ LÝ

CICIDS-2017 [43] được chọn để đánh giá sơ bộ thời gian huấn luyện và kiểm thử vì đây là tập mới nhất trong ba tập phổ biến nhất của các bài khảo sát: UNSW-NB15, CICIDS-2017 và NSL-KDD. CICIDS-2017 dễ tiếp cận và có nhiều ưu điểm. Lưu lượng được thu thập trong nhiều ngày, gồm các cuộc tấn công Brute Force, DoS, Heartbleed, Web Attack, Infiltration, Botnet và DDoS cùng lưu lượng lành tính. Tập dữ liệu có số đặc trưng phong phú và khối lượng lớn hơn nhiều tập phổ biến khác.

Trước khi thí nghiệm, dữ liệu nhiều như các mẫu thiếu nhãn được loại bỏ. Tập cuối cùng có 2.427.193 mẫu. Các nhãn tấn công gốc được gộp thành bảy loại cấp cao: Benign, DoS, DDoS, Web_attack, Brute_Force, BotNet và Infiltration.

Dữ liệu được chia 80% huấn luyện và 20% kiểm thử. Tập dữ liệu mất cân bằng, trong đó lưu lượng lành tính chiếm 84%. Vì mục tiêu là so sánh hiệu quả mô hình, nghiên cứu không xử lý mất cân bằng, bởi yếu tố này không ảnh hưởng trực tiếp đến so sánh thời gian huấn luyện và kiểm thử giữa các dạng chuyển đổi.

Bảng 10. Thống kê nhãn trong CICIDS-2017 dùng cho thí nghiệm

Bảng 10. Thống kê nhãn trong CICIDS-2017 dùng cho thí nghiệm

Nhãn lớp	Loại tấn công gốc	Số lượng
Benign	Normal	2.036.840
DoS	DoS GoldenEye, DoS Slowhttptest, DoS slowloris, DoS Hulk, Heartbleed	192.264
DDoS	DDoS attack-LOIC-UDP, DDoS attack-HOIC, DDoS attacks-LOIC-HTTP	128.007
Web attack	PortScan, XSS, SQL Injection	59.547
Brute force	SSH-Patator, FTP-Patator, FTP-BruteForce, SSH-Bruteforce	8.552
BotNet	Bot	1.947
Infiltration	Infiltration	36
Tổng		**2.427.193**

B. CHUYỂN ĐỔI TẬP DỮ LIỆU VÀ HUẤN LUYỆN MÔ HÌNH

Tập dữ liệu được chuyển sang nhiều dạng biểu diễn để kiểm tra khác biệt hiệu năng.

Biểu diễn số: Dữ liệu được chuyển thành vectơ số 78 chiều, mỗi chiều là một đặc trưng thống kê của luồng mạng. Vectơ được đưa vào DNN gồm các lớp dense kết nối đầy đủ. Hai cấu hình 1D và 2D được đánh giá nhằm xác định ảnh hưởng của số chiều.

Biểu diễn điểm ảnh: Mỗi vectơ số được chuyển thành chuỗi thập lục phân như một dạng nén gọn, sau đó định hình thành ma trận số nguyên không dấu 8 bit, tương ứng giá trị điểm ảnh xám. Nhóm tác giả tạo ảnh xám 9 x 9 và lưu cục bộ. Ảnh được đưa vào Conv2D-CNN. Dữ liệu được điền tuyến tính và đệm 0 tương tự [73]. Vì các luồng có số đặc trưng cố định nên đều vừa kích thước ảnh và không cần cắt.

Biểu diễn chuỗi: Dữ liệu được định hình thành vectơ (78, 1), trong đó 78 là số đặc trưng của mỗi luồng và 1 nghĩa là mỗi đặc trưng được xem như một bước thời gian riêng. Dữ liệu được đưa vào một LSTM đơn giản để kiểm tra hướng dựa trên chuỗi.

Biểu diễn đồ thị: Quy trình tiền xử lý tương tự [74], gồm làm sạch và sắp xếp theo dấu thời gian. Một cấu trúc dựa trên GNN được xây dựng, trong đó địa chỉ IP và luồng mạng được mô hình hóa như các nút trong đồ thị không đồng nhất; cạnh có hướng biểu diễn tương tác giữa các nút. Cập nhật trạng thái dựa trên GRU nắm bắt phụ thuộc thời gian và tăng cường truyền thông điệp. Nút và cạnh được bổ sung các đặc trưng chọn lọc từ dữ liệu thô, chẳng hạn Average Packet Size. Từ các nút, cạnh và đặc trưng tương ứng, đồ thị được xây dựng để nắm bắt thông tin cấu trúc và quan hệ của lưu lượng.

Để giữ kiến trúc đơn giản, số lớp trong mỗi khối Keras Sequential của mô hình đồ thị được giảm xuống hai. Lớp readout tạo dự đoán cuối cùng là mạng fully connected ba lớp. Các thiết lập khác giữ như [74].

Lựa chọn kiến trúc phù hợp với mục tiêu đánh giá ảnh hưởng nền tảng của phép chuyển đổi, thay vì khảo sát các mô hình tiên tiến phức tạp nhất. Vì vậy, nhóm tác giả ưu tiên tính tương thích và đơn giản để tập trung vào biểu diễn dữ liệu.

Tất cả mô hình đều là mô hình học sâu nhẹ, huấn luyện bằng TensorFlow 2.15. Softmax được dùng làm hàm kích hoạt đầu ra, categorical cross-entropy làm hàm mất mát, Adam làm bộ tối ưu và learning rate mặc định là 0,001. Early stopping được áp dụng để thu thập thời gian huấn luyện công bằng vì mỗi mô hình hội tụ sau số epoch khác nhau. Ngoài độ chính xác, thời gian huấn luyện và suy luận cũng được đo để đánh giá hiệu quả tính toán.


C. KẾT QUẢ

Kết quả được thu thập theo nhiều thuộc tính. Độ chính xác được dùng để xác nhận mô hình hoạt động trong khoảng tương tự các nghiên cứu trước trên cùng tập dữ liệu; thời gian huấn luyện và suy luận dùng để đánh giá hiệu quả.

Thời gian huấn luyện khác nhau đáng kể giữa các dạng biểu diễn. Đồ thị nhanh nhất với khoảng 1.096 giây, trong khi chuỗi chậm nhất với 4.069 giây. Số epoch đến hội tụ dao động từ 16 đối với chuỗi đến 27 đối với biểu diễn số 2D. Dù chuỗi có ít epoch nhất, nó vẫn mất thời gian huấn luyện dài nhất.

Trong kiểm thử, độ chính xác của các mô hình nằm trong khoảng đã được báo cáo trong tài liệu cho CICIDS-2017 với dữ liệu luồng và nhiệm vụ đa lớp [55], [59], [71]. Tài liệu báo cáo khoảng 88%-99,87%; thí nghiệm này đạt 89,83%-99,85%. Biểu diễn số 2D thấp nhất với 89,83%. Chuỗi và điểm ảnh đều vượt 99%. Đồ thị và số 1D lần lượt đạt 90,24% và 91,09%.

Về hiệu quả triển khai thực tế, thời gian suy luận của điểm ảnh, đồ thị và số 2D tương tự nhau, lần lượt 32,4 giây, 34,2 giây và 38,2 giây. Mô hình số 1D nhanh nhất với 26,7 giây. Việc không có các phép toán phức tạp như tích chập hoặc lớp hồi quy góp phần làm tính toán nhanh hơn, phù hợp với [75]. Ngược lại, mô hình chuỗi cần 74,8 giây, gần gấp đôi các mô hình khác và bất lợi cho ứng dụng thời gian thực.



Hình 5. Thời gian huấn luyện và suy luận của các dạng biểu diễn. Biểu diễn số 1D và đồ thị có thời gian huấn luyện thấp. Biểu diễn số 2D và điểm ảnh nằm ở mức trung bình, có thời gian suy luận tương tự số 1D và đồ thị. Biểu diễn chuỗi có cả thời gian huấn luyện và suy luận cao.

Kết quả cho thấy phương pháp đồ thị và số có hiệu quả cao trong cả huấn luyện lẫn kiểm thử. Điều này còn được hỗ trợ bởi phần thảo luận tài liệu, nơi hai hướng này đạt hiệu năng cao nhất trên nhiều tập dữ liệu. Do đó, biểu diễn đồ thị và số có tiềm năng rõ rệt cho NIDS thời gian thực và hiệu quả.

Từ các kết quả này, nghiên cứu khuyến nghị phát triển các mô hình học sâu NIDS vừa cải thiện khả năng dự đoán tấn công vừa giảm thời gian suy luận. Người triển khai cũng cần kiểm tra độ vững chắc, có thể thông qua tấn công đối kháng để phát hiện lỗ hổng.

Bảng 11. Thuộc tính của các dạng biểu diễn trên CICIDS-2017

Bảng 11. Thuộc tính của các dạng biểu diễn trên CICIDS-2017

Biểu diễn	Kích thước đầu vào	Loại đầu vào	Kiến trúc mô hình	Tham số huấn luyện	Epoch hội tụ	Độ chính xác	Huấn luyện (giây)	Suy luận (giây)
Số 1D	1D	Vectơ	Fully Connected (256) -> Fully Connected (7)	22.023	19	91,09%	1.798,6	26,7
Số 2D	2D	Ma trận	Conv1D (76, 64) -> MaxPooling1D (38, 64) -> Flatten (2432) -> Fully Connected (7)	158.279	27	89,83%	3.664,9	38,2
Điểm ảnh	2D	Ảnh xám	Conv2D (7, 7, 32) -> MaxPooling2D (3, 3, 32) -> Flatten (288) -> Fully Connected (7)	2.343	26	99,12%	3.967,52	32,4
Chuỗi	2D	Ma trận	SimpleRNN (78, 32) -> Flatten (2496) -> Fully Connected (7)	84.039	16	99,85%	4.068,8	74,8
Đồ thị	2D	Nút, cạnh	GNN: GRUCell(128), nhiều lớp fully connected	282.383	24	90,24%	1.095,84	34,2

VII. THÁCH THỨC VÀ CÁC VẤN ĐỀ NGHIÊN CỨU MỞ

Mặc dù có nhiều phép chuyển đổi dữ liệu, việc xây dựng NIDS cho lưu lượng mạng thực vẫn khó khăn. Chẳng hạn, chuyển dữ liệu mạng thành điểm ảnh để đưa vào CNN tốn thời gian, nên không phù hợp cho ứng dụng thời gian thực. Ngoài ra, vẫn cần phương pháp dựng lại gói gốc để đánh giá chính xác hiệu năng NIDS. Khi chuyển đổi lưu lượng, cần tính đồng thời chi phí xử lý chuyển đổi và chi phí khôi phục ngược.

Một số phương pháp chuyển đổi ở mức luồng, số khác ở mức gói. Lý tưởng nhất là một phương pháp hiệu quả có thể tích hợp cả hai với chi phí thấp. Dù đã có một số phương pháp lai [51], [60], việc thiết kế chuyển đổi khai thác hiệu quả quan hệ giữa dữ liệu mức luồng và mức gói vẫn là vấn đề mở.

Ra quyết định thời gian thực cho từng đơn vị lưu lượng rất quan trọng nhằm giảm độ trễ truyền thông, nhưng chi phí và độ trễ cao của phương pháp dựa trên gói tiếp tục là trở ngại [76]. Một lựa chọn khác là chuyển một phiên luồng thành chuỗi các luồng có chứa đầy đủ gói, thay vì xử lý các luồng hoặc gói cô lập. Cách biểu diễn chuỗi này giúp hiểu hành vi mạng theo thời gian và phát hiện các mẫu có thể bị bỏ sót khi phân tích riêng từng luồng hoặc từng gói.

Một thách thức quan trọng khác là phát hiện sớm. Trong môi trường thực, phát hiện xâm nhập ở giai đoạn đầu có thể ngăn thiệt hại lan rộng và cho phép phản ứng kịp thời. Tuy nhiên, hướng NIDS ảnh hưởng trực tiếp tới tốc độ và tính thực tế của phát hiện. Phát hiện dựa trên luồng thường phải chờ luồng kết thúc mới phân tích, làm chậm phản ứng. Phát hiện dựa trên gói có thể phân tích tức thời từng gói, nhưng đòi hỏi nhiều tài nguyên. Phương pháp lai kế thừa độ trễ của luồng trong khi vẫn tiêu tốn tài nguyên do phân tích gói. Các đánh đổi này cần được nghiên cứu sâu hơn về tác động tới hiệu quả phát hiện sớm.

Dữ liệu gói có nhãn cũng cần được xem xét lại và phải có phương pháp gán nhãn chính xác hơn, vì nhãn là yếu tố quyết định hiệu năng NIDS. Một khả năng là lọc bỏ các phiên lành tính và chỉ giữ lưu lượng độc hại. Lý do là trong một phiên giữa kẻ tấn công và nạn nhân, không phải mọi gói đều độc hại; các gói lành tính có thể xuất hiện xen giữa các hành vi tấn công [54].

Cần thêm các so sánh để xác định biểu diễn phù hợp nhất cho NIDS. Nhiều dạng biểu diễn phải được kiểm thử với nhiều mô hình khác nhau. Thí nghiệm của bài báo chỉ là so sánh bước đầu về hiệu năng dự đoán, tốc độ huấn luyện và tốc độ suy luận.

Ảnh hưởng của biểu diễn cần được khảo sát trên nhiều tập dữ liệu. Các tập khác nhau có thể dẫn tới kết luận khác nhau về biểu diễn tốt nhất. Thí nghiệm bổ sung trên UNSW-NB15, NSL-KDD và các tập mới như RoEduNet-SIMARGL2021 có thể cung cấp hiểu biết sâu hơn theo từng tập. Mỗi biểu diễn cũng nên được kiểm thử với nhiều mô hình để tránh kết quả bị chi phối bởi một kiến trúc cụ thể.

Một hướng khác là nghiên cứu tác động của chuyển đổi khi kết hợp với mô hình phức tạp hơn, chẳng hạn transformer cho dữ liệu chuỗi và mô hình attention cho dữ liệu đồ thị. Nghiên cứu này sử dụng mô hình đơn giản để tập trung vào bản thân phép chuyển đổi. Hạn chế đó có thể được giải quyết bằng một nghiên cứu benchmark, so sánh nhiều mô hình cho từng dạng chuyển đổi.

Cần xác định các chỉ số chuẩn để đánh giá chuyển đổi dữ liệu. Chỉ số nên bao gồm chi phí huấn luyện, thời gian chuyển đổi, hiệu quả phát hiện tấn công và bất thường, đặc biệt đối với tấn công mới, chưa thấy và hành vi hiểm. Một cách đánh giá là loại một số loại tấn công khỏi tập huấn luyện rồi dùng chúng để kiểm thử như tấn công chưa biết hay zero-day.

Cuối cùng, nghiên cứu tương lai cần đánh giá ảnh hưởng của thuật toán chuyển đổi tới hiệu năng NIDS. Thuật toán lựa chọn có thể làm mất hoặc thay đổi dữ liệu ở các mức khác nhau, từ đó ảnh hưởng tới toàn hệ thống.

VIII. KẾT LUẬN

Nghiên cứu tập trung vào các chiến lược chuyển đổi dữ liệu lưu lượng mạng cho mô hình học máy và học sâu. Bốn nhóm chính được xác định gồm biểu diễn số, điểm ảnh, chuỗi và đồ thị. Phân tích xem xét mức độ phổ biến, hiệu năng và hiệu quả của từng nhóm trên nhiều nhiệm vụ và tập dữ liệu; đồng thời trình bày thuật toán chuyển đổi, dữ liệu được sử dụng và mức độ thay đổi cấu trúc gốc.

Nhiều yếu tố cần cân nhắc trong quá trình chuyển đổi: phương pháp mã hóa, các thay đổi áp dụng cho từng phép chuyển đổi, mức độ phù hợp của biểu diễn với mô hình phát hiện, khả năng tương thích với hướng NIDS và hiệu quả tính toán. Việc lựa chọn thường phụ thuộc đặc điểm tập dữ liệu và yêu cầu của nhiệm vụ phát hiện.

Kết quả từ tài liệu và thí nghiệm cho thấy thời gian huấn luyện và hiệu năng thay đổi giữa các dạng biểu diễn. Có sự đánh đổi giữa độ chính xác và tốc độ xử lý; đây là hướng cần tiếp tục nghiên cứu.

Trong tương lai, cần khảo sát các phương pháp có tính đến chuyển đổi đảo ngược, đặc biệt trong kịch bản tấn công đối kháng. Việc cải thiện gán nhãn tập dữ liệu, báo cáo thời gian suy luận và đánh giá kỹ thuật chuyển đổi nhằm giảm mất mát dữ liệu cũng rất quan trọng. Những yếu tố này hỗ trợ hệ thống thời gian thực và bảo đảm độ tin cậy của dữ liệu đã chuyển đổi.

LỜI CẢM ƠN

Các kết quả trình bày trong công trình này hoàn toàn thuộc trách nhiệm của các tác giả.

TÀI LIỆU THAM KHẢO

- [1] A. Drewek-Ossowicka, M. Pietrolaj, and J. Rumiński, “A survey of neural networks usage for intrusion detection systems,” *J. Ambient Intell. Humanized Comput.*, vol. 12, no. 1, pp. 497–514, Jan. 2021.
- [2] S. Kumar, S. Gupta, and S. Arora, “Research trends in network- based intrusion detection systems: A review,” *IEEE Access*, vol. 9, pp. 157761–157779, 2021.
- [3] B. Andreas, J. Dilruksha, and E. McCandless, “Flow-based and packet- based intrusion detection using blstm,” *SMU Data Sci. Rev.*, vol. 3, no. 3, p. 8, 2021.
- [4] J. J. Davis and A. J. Clark, “Data preprocessing for anomaly based network intrusion detection: A review,” *Comput. Secur.*, vol. 30, nos. 6–7, pp. 353–375, Sep. 2011.
- [5] L. D. Manocchio, S. Layeghy, W. W. Lo, G. K. Kulatilleke, M. Sarhan, and M. Portmann, “FlowTransformer: A transformer framework for flow- based network intrusion detection systems,” *Expert Syst. Appl.*, vol. 241, May 2024, Art. no. 122564.
- [6] O. E. Elejla, M. Anbar, S. Hamouda, B. Belaton, T. A. Al-Amiedy, and I. H. Hasbullah, “Flow-based IDS features enrichment for ICMPv6-DDoS attacks detection,” *Symmetry*, vol. 14, no. 12, p. 2556, Dec. 2022.
- [7] H. Alaidaros, M. Mahmuddin, and A. Al Mazari, “An overview of flow- based and packet-based intrusion detection performance in high-speed networks,” in *Proc. Int. Arab Conf. Inf. Technol.*, Jan. 2011, pp. 1–9.
- [8] S. Golubev, E. Novikova, and E. Fedorchenko, “Image-based approach to intrusion detection in cyber-physical objects,” *Information*, vol. 13, no. 12, p. 553, Nov. 2022.
- [9] A. Cheng, “PAC-GAN: Packet generation of network traffic using generative adversarial networks,” in *Proc. IEEE 10th Annu. Inf. Technol., Electron. Mobile Commun. Conf. (IEMCON)*, Oct. 2019, pp. 728–734.
- [10] Y. Alaca and Y. Çelik, “Cyber attack detection with QR code images using lightweight deep learning models,” *Comput. Secur.*, vol. 126, Mar. 2023, Art. no. 103065.
- [11] I.-T. Lee, M. Marwah, and M. Arlitt, “Attention-based self-supervised feature learning for security data,” 2020, arXiv:2003.10639.
- [12] Y. Hao, Y. Sheng, and J. Wang, “A graph representation learning algorithm for low-order proximity feature extraction to enhance unsupervised IDS preprocessing,” *Appl. Sci.*, vol. 9, no. 20, p. 4473, Oct. 2019.
- [13] Q. Cheng, S. Zhou, Y. Shen, D. Kong, and C. Wu, “Packet-level adversarial network traffic crafting using sequence generative adversarial networks,” 2021, arXiv:2103.04794.
- [14] S. Hore, J. Ghadermazi, D. Paudel, A. Shah, T. K. Das, and N. D. Bastian, “Deep PackGen: A deep reinforcement learning framework for adversarial network packet generation,” *ACM Trans. Privacy Secur.*, vol. 28, no. 2, pp. 1–33, May 2025.
- [15] G. Andresini, A. Appice, L. De Rose, and D. Malerba, “GAN augmentation to deal with imbalance in imaging-based intrusion detection,” *Future Gener. Comput. Syst.*, vol. 123, pp. 108–127, Oct. 2021.
- [16] Z. Lin, Y. Shi, and Z. Xue, “IDSGAN: Generative adversarial networks for attack generation against intrusion detection,” 2018, arXiv:1809.02077.
- [17] M. Usama, M. Asim, S. Latif, J. Qadir, and A. Al-Fuqaha, “Generative adversarial networks for launching and thwarting adversarial attacks on network intrusion detection systems,” in *Proc. 15th Int. Wireless Commun. Mobile Comput. Conf. (IWCMC)*, Jun. 2019, pp. 78–83.
- [18] B.-E. Zolbayer, R. Sheatsley, P. McDaniel, M. J. Weisman, S. Zhu, S. Zhu, and S. Krishnamurthy, “Generating practical adversarial network traffic flows using NIDSGAN,” 2022, arXiv:2203.06694.
- [19] L. Han, Y. Sheng, and X. Zeng, “A Packet-Length-Adjustable attention model based on bytes embedding using flow-WGAN for smart cybersecu- rity,” *IEEE Access*, vol. 7, pp. 82913–82926, 2019.
- [20] C. Y. Li, R. Sánchez-Matilla, A. S. Shamsabadi, R. Mazzon, and A. Cavallaro, “On the reversibility of adversarial attacks,” in *Proc. IEEE Int. Conf. Image Process. (ICIP)*, Sep. 2021, pp. 3073–3077.
- [21] L. A. H. Ahmed, Y. A. M. Hamad, and A. A. M. A. Abdalla, “Network- based intrusion detection datasets: A survey,” in *Proc. Int. Arab Conf. Inf. Technol. (ACIT)*, Nov. 2022, pp. 1–7.

- [22] J. Verma, A. Bhandari, and G. Singh, "Review of existing data sets for network intrusion detection system," *Adv. Math., Sci. J.*, vol. 9, no. 6, pp. 3849–3854, Jul. 2020.
- [23] M. Ghurab, G. Gaphari, F. Alshami, R. Alshamy, and S. Othman, "A detailed analysis of benchmark datasets for network intrusion detection system," *Asian J. Res. Comput. Sci.*, vol. 7, pp. 14–33, Apr. 2021.
- [24] A. Thakkar and R. Lohiya, "A review of the advancement in intrusion detection datasets," *Proc. Comput. Sci.*, vol. 167, pp. 636–645, Apr. 2020.
- [25] M. Ring, S. Wunderlich, D. Scheuring, D. Landes, and A. Hotho, "A survey of network-based intrusion detection data sets," *Comput. Secur.*, vol. 86, pp. 147–167, Sep. 2019.
- [26] Y. Hamid, V. R. Balasaraswathi, L. Journaux, and M. Sugumaran, "Benchmark datasets for network intrusion detection: A review," *Int. J. Netw. Secur.*, vol. 20, no. 4, pp. 645–654, Jul. 2018.
- [27] H. Hindy, D. Brosset, E. Bayne, A. Seeam, C. Tachtatzis, R. Atkinson, and X. Bellekens, "A taxonomy of network threats and the effect of current datasets on intrusion detection systems," *IEEE Access*, vol. 8, pp. 104650–104675, 2020.
- [28] G. Singh and N. Khare, "A survey of intrusion detection from the perspective of intrusion datasets and machine learning techniques," *Int. J. Comput. Appl.*, vol. 44, no. 7, pp. 659–669, Jul. 2022.
- [29] X. Zhang, J. Chen, Y. Zhou, L. Han, and J. Lin, "A multiple-layer representation learning model for network-based attack detection," *IEEE Access*, vol. 7, pp. 91992–92008, 2019.
- [30] J. Krupski, W. Graniszewski, and M. Iwanowski, "Data transformation schemes for CNN-based network traffic analysis: A survey," *Electronics*, vol. 10, no. 16, p. 2042, Aug. 2021.
- [31] M. Sarhan, S. Layeghy, and M. Portmann, "Towards a standard feature set for network intrusion detection system datasets," *Mobile Netw. Appl.*, vol. 27, no. 1, pp. 357–370, Feb. 2022.
- [32] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [33] M. Marwah and M. Arlitt, "Deep learning for network traffic data," in *Proc. 28th ACM SIGKDD Conf. Knowl. Discovery Data Mining*, Aug. 2022, pp. 4804–4805.
- [34] Y. A. Farrukh, I. Khan, S. Wali, D. Bierbrauer, J. A. Pavlik, and N. D. Bastian, "Payload-byte: A tool for extracting and labeling packet capture files of modern network intrusion detection datasets," in *Proc. IEEE/ACM Int. Conf. Big Data Comput., Appl. Technol. (BDCAT)*, Dec. 2022, pp. 58–67.
- [35] R. P. Lippmann, D. J. Fried, I. Graf, J. W. Haines, K. R. Kendall, D. McClung, D. Weber, S. E. Webster, D. Wyschogrod, R. K. Cunningham, and M. A. Zissman, "Evaluating intrusion detection systems: The 1998 DARPA off-line intrusion detection evaluation," in *Proc. DARPA Inf. Survivability Conf. Expo. (DISCEX)*, vol. 2, Feb. 2000, pp. 12–26.
- [36] S. J. Stolfo, W. Fan, W. Lee, A. Prodromidis, and P. K. Chan, "Cost-based modeling for fraud and intrusion detection: Results from the JAM project," in *Proc. DARPA Inf. Survivability Conf. Expo. (DISCEX)*, vol. 2, 2000, pp. 130–144.
- [37] R. Pang, M. Allman, M. Bennett, J. Lee, V. Paxson, and B. Tierney, "A first look at modern enterprise traffic," in *Proc. 5th ACM SIGCOMM Conf. Internet Meas. (IMC)*, 2005, p. 1.
- [38] J. Song, H. Takakura, Y. Okabe, M. Eto, D. Inoue, and K. Nakao, "Statistical analysis of honeypot data and building of Kyoto 2006+ dataset for NIDS evaluation," in *Proc. 1st Workshop Building Anal. Datasets Gathering Exper. Returns Secur.*, New York, NY, USA, Apr. 2011, pp. 29–36.
- [39] M. Tavallaee, E. Bagheri, W. Lu, and A. A. Ghorbani, "A detailed analysis of the KDD CUP 99 data set," in *Proc. IEEE Symp. Comput. Intell. Secur. Defense Appl.*, Jul. 2009, pp. 1–6.
- [40] A. Shiravi, H. Shiravi, M. Tavallaee, and A. A. Ghorbani, "Toward developing a systematic approach to generate benchmark datasets for intrusion detection," *Comput. Secur.*, vol. 31, no. 3, pp. 357–374, May 2012.
- [41] A. R. Vasudevan, E. Harshini, and S. Selvakumar, "SSENet-2011: A network intrusion detection system dataset and its comparison with KDD CUP 99 dataset," in *Proc. 2nd Asian Himalayas Int. Conf. Internet (AH- ICI)*, Nov. 2011, pp. 1–5.
- [42] N. Moustafa and J. Slay, "UNSW-NB15: A comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set)," in *Proc. Mil. Commun. Inf. Syst. Conf. (MilCIS)*, Nov. 2015, pp. 1–6.
- [43] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward generating a new intrusion detection dataset and intrusion traffic characterization," in *Proc. 4th Int. Conf. Inf. Syst. Secur. Privacy*, 2018, pp. 108–116.

- [44] I. Sharafaldin, A. Habibi Lashkari, S. Hakak, and A. A. Ghorbani, “Developing realistic distributed denial of service (DDoS) attack dataset and taxonomy,” in *Proc. Int. Carnahan Conf. Secur. Technol. (ICCST)*, Oct. 2019, pp. 1–8.
- [45] M.-E. Mihailescu, D. Mihai, M. Carabas, M. Komisarek, M. Pawlicki, W. Hołubowicz, and R. Kozik, “The proposition and evaluation of the RoEduNet-SIMARGL2021 network intrusion detection dataset,” *Sensors*, vol. 21, no. 13, p. 4319, Jun. 2021.
- [46] M. J. De Lucia, P. E. Maxwell, N. D. Bastian, A. Swami, B. Jalaian, and N. Leslie, “Machine learning raw network traffic detection,” *Proc. SPIE*, vol. 11746, no. 117460V, pp. 1–11, Apr. 2021.
- [47] G. Marín, P. Caasas, and G. Capdehourat, “DeepMAL–Deep learning models for malware traffic detection and classification,” in *Data Science— Analytics and Applications*. Wiesbaden, Germany: Springer, Jan. 2021, pp. 105–112.
- [48] G. Marín, P. Casas, and G. Capdehourat, “RawPower: Deep learning based anomaly detection from raw network traffic measurements,” in *Proc. ACM SIGCOMM Conf. Posters Demos*, New York, NY, USA, Aug. 2018, pp. 75–77.
- [49] Y. Yu and N. Bian, “An intrusion detection method using few-shot learning,” *IEEE Access*, vol. 8, pp. 49730–49740, 2020.
- [50] Y. Chen, J. Li, and N. Guo, “Efficient and interpretable SRU combined with TabNet for network intrusion detection in the big data environment,” *Int. J. Inf. Secur.*, vol. 22, no. 3, pp. 679–689, Jun. 2023.
- [51] P. R. Kanna, S. Rajasekar, P. Santhi, and G. Sathish, “Mshids: Multi-stage hybrid intrusion detection system using flow and packet-based intrusion analysis in big data environment,” *SSRN Electron. J.*, Jan. 2023.
- [52] W. Wang, Y. Sheng, J. Wang, X. Zeng, X. Ye, Y. Huang, and M. Zhu, “HAST-IDS: Learning hierarchical spatial-temporal features using deep neural networks to improve intrusion detection,” *IEEE Access*, vol. 6, pp. 1792–1806, 2018.
- [53] T. Kim and W. Pak, “Deep learning-based network intrusion detection using multiple image transformers,” *Appl. Sci.*, vol. 13, no. 5, p. 2754, Feb. 2023.
- [54] J. Ghadermazi, A. Shah, and N. D. Bastian, “Towards real-time network intrusion detection with image-based sequential packets representation,” *IEEE Trans. Big Data*, vol. 11, no. 1, pp. 157–173, Feb. 2025.
- [55] T. Kim, S. C. Suh, H. Kim, J. Kim, and J. Kim, “An encoding technique for CNN-based network anomaly detection,” in *Proc. IEEE Int. Conf. Big Data (Big Data)*, Dec. 2018, pp. 2960–2965.
- [56] Z. Li, Z. Qin, K. Huang, X. Yang, and S. Ye, “Intrusion detection using convolutional neural networks for representation learning,” in *Proc. Neural Inf. Process.*, Nov. 2017, pp. 858–866.
- [57] F. Hu, S. Zhang, X. Lin, L. Wu, N. Liao, and Y. Song, “Network traffic classification model based on attention mechanism and spatiotemporal features,” *EURASIP J. Inf. Secur.*, vol. 2023, no. 1, p. 6, Jul. 2023.
- [58] P. Jaroensiripong, K. Sumongkayothin, P. Siritanawan, and K. Kotani, “Cybersecurity intrusion detection with image classification model using Hilbert curve,” in *Proc. 19th Int. Joint Conf. Comput. Vis., Imag. Comput. Graph. Theory Appl.*, 2024, pp. 325–332.
- [59] A. S. Khan, Z. Ahmad, J. Abdullah, and F. Ahmad, “A spectrogram image- based network anomaly detection system using deep convolutional neural network,” *IEEE Access*, vol. 9, pp. 87079–87093, 2021.
- [60] M. He, X. Wang, L. Jin, B. Dai, K. Kacuilu, and X. Xue, “Malicious network behavior detection using fusion of packet captures files and business feature data,” *Sensors*, vol. 21, no. 17, p. 5942, Sep. 2021.
- [61] C. Li, J. Wang, and X. Ye, “Using a recurrent neural network and restricted Boltzmann machines for malicious traffic detection,” *NeuroQuantology*, vol. 16, no. 5, pp. 823–831, May 2018.
- [62] W. Wang, S. Jian, Y. Tan, Q. Wu, and C. Huang, “Robust unsupervised network intrusion detection with self-supervised masked context reconstruction,” *Comput. Secur.*, vol. 128, May 2023, Art. no. 103131.
- [63] B. Lindauer, “Insider threat test dataset,” *Carnegie Mellon Univ.*, Sep. 2020, doi: 10.1184/R1/12841247.v1.
- [64] P. Torres, C. Catania, S. Garcia, and C. Garcia Garino, “An analysis of recurrent neural networks for botnet detection behavior,” in *Proc. IEEE Biennial Congr. Argentina (ARGENCON)*, Jun. 2016, pp. 1–6.
- [65] F. Ullah, S. Ullah, G. Srivastava, and J. C.-W. Lin, “IDS-INT: Intrusion detection system using transformer-based transfer learning for imbalanced network traffic,” *Digit. Commun. Netw.*, vol. 10, no. 1, pp. 190–204, Feb. 2024.
- [66] T. Bilot, N. E. Madhoun, K. Al Agha, and A. Zouaoui, “Graph neural networks for intrusion detection: A survey,” *IEEE Access*, vol. 11, pp. 49114–49139, 2023.

- [67] L. Zheng, Z. Li, J. Li, Z. Li, and J. Gao, “AddGraph: Anomaly detection in dynamic graph using attention-based temporal GCN,” in Proc. 28th Int. Joint Conf. Artif. Intell., Aug. 2019, pp. 4419–4425.
- [68] A. Venturi, M. Ferrari, M. Marchetti, and M. Colajanni, “ARGANIDS: A novel network intrusion detection system based on adversarially regularized graph autoencoder,” in Proc. 38th ACM/SIGAPP Symp. Appl. Comput., New York, NY, USA, Mar. 2023, pp. 1540–1548.
- [69] P. G. H. Lehot, “An optimal algorithm to detect a line graph and output its root graph,” J. ACM, vol. 21, no. 4, pp. 569–575, Oct. 1974.
- [70] S. Chen, D. Lin, Z. Xie, and H. Wang, “Temporal-gated graph neural network with graph sampling for multi-step attack detection,” in Proc. IEEE 22nd Int. Conf. Trust, Secur. Privacy Comput. Commun. (TrustCom), Nov. 2023, pp. 1266–1271.
- [71] M. Zhong, M. Lin, and Z. He, “Dynamic multi-scale topological representation for enhancing network intrusion detection,” Comput. Secur., vol. 135, Dec. 2023, Art. no. 103516.
- [72] M. Rodríguez, Á. Alesanco, L. Mehavilla, and J. García, “Evaluation of machine learning techniques for traffic flow-based intrusion detection,” Sensors, vol. 22, no. 23, p. 9326, Nov. 2022.
- [73] W. Wang, M. Zhu, X. Zeng, X. Ye, and Y. Sheng, “Malware traffic classification using convolutional neural network for representation learning,” in Proc. 31st Int. Conf. Inf. Netw. (ICOIN), Jan. 2017, pp. 712–717.
- [74] D. Pujol-Perich, J. Suárez-Varela, A. Cabellos-Aparicio, and P. Barlet- Ros, “Unveiling the potential of graph neural networks for robust intrusion detection,” 2021, arXiv:2107.14756.
- [75] D. Ramalingam, “A supervised hybrid DNN for real-time intrusion detection in firewalls,” J. Electr. Syst., vol. 20, no. 3, pp. 1139–1160, Apr. 2024.
- [76] S. Chowdhury, B. Liang, A. Tizghadam, and I. Albanese, “Flow-packet hybrid traffic classification for class-aware network routing,” in Proc. IEEE Global Commun. Conf. (GLOBECOM), Dec. 2021, pp. 1–6.

TIỂU SỬ TÁC GIẢ

Somaya Eltanbouly nhận bằng Thạc sĩ Khoa học Máy tính tại Đại học Qatar năm 2024, chuyên về thực tế ảo và học máy, tập trung vào các ứng dụng và thách thức liên quan. Hiện cô là trợ lý nghiên cứu tại Đại học Qatar. Hướng nghiên cứu của cô gồm ứng dụng học máy trong nhiều lĩnh vực.

Jezia Zakraoui nhận bằng thạc sĩ và tiến sĩ Khoa học Máy tính tại Đại học Công nghệ Vienna, Áo, năm 2012. Hiện cô là nghiên cứu viên sau tiến sĩ tại Đại học Qatar. Cô đã công bố nhiều bài trên các tạp chí bình duyệt xếp hạng cao. Hướng nghiên cứu gồm khai phá văn bản, xử lý ngôn ngữ tự nhiên, dịch máy, học sâu, học máy, thị giác máy tính, mô hình GAN và sinh mô tả ảnh.

Abdulaziz Al-Ali nhận bằng cử nhân và thạc sĩ Kỹ thuật Máy tính cùng bằng tiến sĩ Học máy tại Đại học Miami, Florida, Hoa Kỳ. Hiện ông là trợ lý giáo sư tại Khoa Khoa học và Kỹ thuật Máy tính, Đại học Qatar. Ngoài phát triển kỹ thuật học máy mới, nghiên cứu hiện tại của ông gồm xây dựng mô hình dự đoán cho dữ liệu phi cấu trúc, văn bản, hình ảnh, chuỗi thời gian và dữ liệu sinh trắc học. Ông nhận nhiều khoản tài trợ từ Quỹ Nghiên cứu Quốc gia Qatar và doanh nghiệp, dẫn tới các công bố ở hội nghị và tạp chí hàng đầu. Ông từng biên tập sách về phân tích dữ liệu và tham gia nhiều ủy ban cấp quốc gia tại Qatar.

Abdelhak Belhi nhận bằng thạc sĩ Kỹ thuật Phần mềm và Xử lý Thông tin tại Đại học Boumerdes, Algeria, và bằng tiến sĩ Khoa học Máy tính tại Đại học Lyon, Pháp. Hiện ông là trợ lý giáo sư tại Học viện Nghiên cứu Quốc phòng Joaan Bin Jassim, Qatar. Ông đã công bố nhiều bài trên tạp chí bình duyệt xếp hạng cao và tham gia nhiều hội nghị quốc tế trong các lĩnh vực trí tuệ nhân tạo, hệ thống thông tin và an ninh mạng. Ông đồng biên tập một cuốn sách về phân tích dữ liệu trong văn hóa số và là phản biện cho nhiều tạp chí hàng đầu về học máy và học sâu. Hướng nghiên cứu hiện tại gồm AI, học máy, an ninh mạng và blockchain.

Sandy Rahme nhận bằng thạc sĩ về hệ thống tự động, máy tính và ra quyết định, cùng bằng tiến sĩ về hệ thống tự động tại Đại học Paul Sabatier, Pháp. Trong lý thuyết điều khiển, nghiên cứu của cô tập trung vào chẩn đoán lỗi cho hệ phi tuyến, tuyến tính và LPV có biến lập lịch không chắc chắn, ứng dụng cho tua-bin khí công nghiệp, lò phản ứng đồng trùng hợp, chẩn đoán lỗi mạng quy mô lớn và điều khiển vi lưới một chiều. Trong truyền thông, cô nghiên cứu ước lượng và phát hiện bất thường trong mạng TCP/IP. Gần đây, cô tham gia nghiên cứu né tránh hệ thống phát hiện xâm nhập bằng kỹ thuật học máy.

Abdelaziz Bouras nhận bằng tiến sĩ Khoa học Máy tính tại Đại học Lyon, Pháp, và bằng Tiến sĩ Danh dự Khoa học của Đại học Chiang Mai, Thái Lan, do Công chúa Maha Chakri Sirindhorn trao. Hiện ông là giáo sư tại Khoa Khoa học và Kỹ thuật Máy tính, Đại học Qatar, nơi ông từng tham gia với vai trò chủ nhiệm của ictQatar thuộc Bộ. Trước đó, ông là giáo sư tại Đại học Lyon và lãnh đạo nhóm nghiên cứu về hệ thống thông tin và hỗ trợ quyết định. Ông đồng sáng lập và làm biên tập cho nhiều tạp chí quốc tế. Hướng nghiên cứu hiện tại gồm AI và hệ thống phân tán cho kỹ thuật vòng đời. Ông là chủ tịch sáng lập IFIP WG 5.1 về ICT cho phát triển sản phẩm toàn cầu trong toàn bộ vòng đời.